

Desarrollo de un sistema de decodificación neuronal del habla para restauración de la comunicación

Memoria del TFM

UOC

Lucas Zamora Vera

Máster Ciencia de Datos
Área 2

Tutor/a de TF

José Andrés González López

Profesor/a responsable de la asignatura

Esther Ibáñez Marcelo

Fecha Entrega: 05/2026

Universitat Oberta
de Catalunya



Esta obra está sujeta a una licencia de Reconocimiento-
NoComercial-SinObraDerivada [3.0 España de Creative Commons](https://creativecommons.org/licenses/by-nc-nd/3.0/es/)

Ficha del Trabajo Final

Título del trabajo:	Desarrollo de un sistema de decodificación neuronal del habla para restauración de la comunicación
Nombre del autor/a:	Lucas Zamora Vera
Nombre del Tutor/a de TF:	José Andrés González López
Nombre del/de la PRA:	Esther Ibáñez Marcelo
Fecha de entrega:	06/2026
Titulación o programa:	Máster Ciencia de Datos
Área del Trabajo Final:	Área 2
Idioma del trabajo:	Castellano
Palabras clave	"intracortical neural decoding", "brain-to-text", "deep learning"
Resumen del Trabajo	
Este estudio presenta el diseño, desarrollo y evaluación de un sistema de decodificación "brain-to-text" que convierte actividad neuronal relacionada con habla en transcripciones de texto. El contexto de aplicación se enmarca en neuroprótesis de comunicación para personas con trastornos del habla, donde la recuperación de un canal comunicativo fiable puede aumentar de forma significativa la autonomía y la participación social. El problema abordado consiste en mapear series multicanal de señales neuronales, de longitud variable, a transcripciones de frases sin alineamiento explícito entre la señal y las palabras. Para ello, se propone un sistema de decodificación de señales neuronales basado en modelos de deep learning capaz de traducir actividad cerebral relacionada con habla imaginada en texto, con una extensión a síntesis de voz. El trabajo parte de una línea base recurrente reproducible y explora distintas alternativas de modelado, incluyendo arquitecturas de espacio de estados, su combinación con modelos de lenguaje y variantes de decodificación directa sin etapa lingüística intermedia. Los resultados se reportan mediante WER ("word error rate"), junto con el desglose de inserciones, borrados y sustituciones, así como estudios de ablación para analizar la contribución de cada componente del sistema. El trabajo se orienta a reducir el error respecto al modelo base y a analizar los principales factores que condicionan el	

rendimiento.

Finalmente, se discuten implicaciones clínicas, reproducibilidad, eficiencia computacional y consideraciones éticas relacionadas con la privacidad de datos neuronales.

Abstract

This study presents the design, development, and evaluation of a "brain-to-text" decoding system that converts speech-related neural activity into text transcriptions. The application context lies in communication neuroprostheses for people with speech disorders, where the recovery of a reliable communication channel can significantly improve autonomy and social participation. The problem addressed consists of mapping variable-length multichannel neural signal sequences to sentence-level transcriptions without explicit alignment between the signal and the words.

To this end, a neural-signal decoding system based on deep learning models is proposed, capable of translating brain activity related to imagined speech into text, with an extension to speech synthesis. The work starts from a reproducible recurrent baseline and explores different modeling alternatives, including state-space architectures, their combination with language models, and direct decoding variants without an intermediate linguistic stage.

Results are reported using WER ("word error rate"), together with a breakdown into insertions, deletions, and substitutions, as well as ablation studies to analyze the contribution of each system component. The work is aimed at reducing the error with respect to the baseline model and analyzing the main factors that influence performance.

Finally, clinical implications, reproducibility, computational efficiency, and ethical considerations related to neural data privacy are discussed.

Index

1.	Introducción	1
1.1.	Contexto y justificación del Trabajo	1
1.2.	Descripción general	1
1.3.	Motivación personal	2
1.4.	Impacto en sostenibilidad, ético-social y de diversidad	2
1.5.	Objetivos	3
1.6.	Enfoque y método a seguir	4
1.6.1	Estrategia de investigación	4
1.6.2	Fases del desarrollo	5
1.7.	Planificación	5
1.7.1	Tareas	5
1.7.2	Calendario	6
1.7.3	Hitos	6
1.7.4	Análisis de riesgos	7
1.8.	Resultados esperados	7
1.9	Estructura de la memoria	8
2.	Estado del arte	9
2.1.	Problema clínico y necesidad de comunicación asistida	9
2.2.	De las BCIs generales a neuroprótesis del habla	9
2.3.	Bases neurofuncionales de la producción y decodificación del habla	11
2.4.	Tipos de señal y grado de invasividad	13
2.5.	Paradigmas de salida en neuroprótesis de comunicación	14
2.6.	Pipeline técnico de sistemas brain-to-text	16
2.6.1	Gestión de secuencias de longitud variable y ausencia de alineamiento explícito	16
2.6.2	Modelos secuencia-a-secuencia aplicados al problema: RNN, atención y Transformers	17
2.6.3	Decodificación neuronal en dos etapas: de actividad neural a fonemas y de fonemas a texto	18
2.7.	Evaluación	19
2.8.	Benchmarks, reproducibilidad y limitaciones	20
2.9.	Posicionamiento del TFM en el contexto actual	21

3.	Diseño e implementación del sistema	22
3.1	Visión general del sistema	22
3.2	Entorno de desarrollo y reproducibilidad	23
3.3	Datos, análisis exploratorio y preprocesado	24
3.3.1	Consideraciones derivadas del análisis de datos	25
3.3.2	Representaciones objetivo	25
3.3.3	Preprocesado de la señal neuronal	26
3.4	Modelo de decodificación neuronal	27
3.4.1	Formulación común del problema	27
3.4.2	Arquitecturas evaluadas	28
3.4.3	Variante fonética	31
3.4.4	Variante textual	31
3.5	Decodificación lingüística y rescoring	32
3.6	Síntesis de voz	34
4.	Evaluación experimental y resultados	36
4.1	Protocolo experimental y métricas	36
4.2	Resultados de la variante fonética	37
4.2.1	Tasas de error en fonemas	37
4.2.2	Comparación en WER tras modelo de lenguaje	38
4.3	Resultados de la variante textual	39
	Efecto del modelo de lenguaje en el rescoring textual	40
4.4	Comparación entre variantes fonética y textual	41
4.5	Análisis de errores	42
4.5.1	Análisis de errores en la variante fonética	42
4.5.2	Análisis de errores en la variante textual	47
4.5.3	Ejemplos cualitativos de síntesis de voz	52
4.6	Discusión global de resultados	53
5.	Conclusiones y líneas de trabajo futuras	56
5.1	Conclusiones	56
5.2	Limitaciones	57
5.3	Líneas de trabajo futuras	58
6.	Bibliografía	60
7.	Anexos	62

Anexo A. Análisis exploratorio de datos	62
A.1 Estructura del conjunto de datos	62
A.2 Distribución de ensayos por sesión	63
A.3 Longitudes de las secuencias de entrada y salida	64
A.4 Relación entre longitud temporal y longitud lingüística	65
A.5 Estabilidad y variabilidad intersesión de la señal	66
A.6 Conclusiones del análisis exploratorio de datos	68
Anexo B. Repositorio del trabajo desarrollado	69
Anexo C. Repositorio del modelo base utilizado	69
Anexo D. Repositorio Pages.io de reproducción de ejemplos sintetizados	70
Anexo E. Organización del código y artefactos experimentales	71

Lista de Figuras

Figura 1 Cronograma general del TFM. Fuente: elaboración propia.	6
Figura 2. Esquema de funcionamiento de una BCI basada en P300. Fuente: adaptado de Overlapped Partitioning for Ensemble Classifiers of P300-Based Brain-Computer Interfaces, PLOS One, 2014. Licencia CC BY 4.0.	10
Figura 3. Hitos principales del desarrollo de las neuroprótesis del habla. Fuente: adaptado de Silva y otros [1].	11
Figura 4. Principales regiones corticales implicadas en el procesamiento del lenguaje. Fuente: adaptado de Friederici AD. "The Brain Basis of Language Processing: From Structure to Function". Physiol Rev. 2011;91(4). doi:10.1152/physrev.00006.2011.	12
Figura 5. Comparación esquemática entre EEG, ECoG y registros intracorticales. Fuente: adaptado de Alahi MEE y otros, Recent advancement of electrocorticography (ECoG) electrodes for chronic neural recording/stimulation. Mater Today Commun. 2021. doi:10.1016/j.mtcomm.2021.102853 [12].	13
Figura 6. Esquema general de los paradigmas de salida en neuroprótesis de comunicación. Fuente: elaboración propia.	15
Figura 7 Visión general del pipeline de decodificación brain-to-text. Fuente: adaptado de Li y otros [18].	17
Figura 8. Esquema de decodificación en dos etapas desde actividad neural a fonemas y de fonemas a texto. Fuente: adaptado de Card y otros, An accurate and rapidly calibrating speech neuroprosthesis. N Engl J Med. 2024;391:609-618.[2]	18
Figura 9. Pipeline general del sistema de decodificación neuronal a texto y voz. Fuente: elaboración propia.	22
Figura 10. Efecto del suavizado gaussiano sobre una señal neuronal. Fuente: elaboración propia.	26
Figura 11. Arquitectura general de las variantes implementadas. Fuente: elaboración propia.	30
Figura 12. Representación esquemática de la salida temporal del decodificador neuronal como matriz de logits.	32
Figura 13. Proceso de decodificación y rescoring para las variantes fonética y textual. Fuente: elaboración propia.	33
Figura 14. Integración del módulo TTS como extensión del sistema. Fuente: elaboración propia.	34

Figura 15. Evolución del PER y WER fonémicos en función de la longitud de la frase. Fuente: elaboración propia.	43
Figura 16. Evolución de PER y WER por sesión en la variante fonética. Fuente: elaboración propia.	43
Figura 17. Matriz de confusión reducida para las sustituciones fonémicas más frecuentes. Fuente: elaboración propia.	45
Figura 18. Relación entre la frecuencia de aparición del fonema y su tasa de sustitución. Fuente: elaboración propia.	45
Figura 19. CER medio en función de la longitud de la frase en la rama textual. Fuente: elaboración propia.	48
Figura 20. WER medio en función de la longitud de la frase en la rama textual. Fuente: elaboración propia.	48
Figura 21. Evolución del WER medio por sesión en orden cronológico en la rama textual. Fuente: elaboración propia.	49
Figura 22. Matriz de confusión reducida para las confusiones léxicas más frecuentes en la rama textual. Fuente: elaboración propia.	49
Figura 23. Forma de onda y espectrograma del audio sintetizado para un ejemplo correctamente decodificado por la variante fonética. Fuente: elaboración propia.....	52
Figura 24. Ejemplo de señal neuronal de entrada correspondiente a un ensayo individual. Fuente: elaboración propia.	63
Figura 25. Número de ensayos disponibles por sesión de registro. Fuente: elaboración propia.....	64
Figura 26. Distribución de la longitud temporal de las secuencias de entrada en entrenamiento y validación. Fuente: elaboración propia.....	64
Figura 27 .Distribución de las longitudes de las secuencias objetivo en las representaciones fonética y textual. Fuente: elaboración propia.	65
Figura 28. Relación entre la longitud temporal de entrada y la longitud de la secuencia objetivo. Fuente: elaboración propia.	66
Figura 29. Estabilidad temporal global de la señal por sesión de registro, medida mediante la media del valor absoluto, la desviación estándar y el RMS. Fuente: elaboración propia.....	67
Figura 30. Mapa de calor de la variabilidad media de la señal por sesión y característica. Fuente: elaboración propia.	68

Lista de Tablas

Tabla 1. Planificación de tareas del TFM y relación con objetivos.....	6
Tabla 2. Principales riesgos del TFM y medidas de mitigación.....	7
Tabla 3. Estudios y métricas de referencia en neuroprótesis "brain-to-text".	20
Tabla 4. Configuración del entorno de desarrollo y ejecución experimental.	23
Tabla 5. Distribución de ensayos por partición del conjunto de datos.....	24
Tabla 6. Resumen de arquitecturas implementadas.....	30
Tabla 7. Resumen de resultados PER en la rama fonética	37
Tabla 8. Resumen de resultados WER en la variante fonética.	38
Tabla 9. Resumen de resultados de la rama textual con el mejor modelo de lenguaje.....	39
Tabla 10. Mejores resultados de rescoring textual para la arquitectura ConvMambaGRU textual según el modelo de lenguaje utilizado.	40
Tabla 11. Comparación entre las mejores variantes de la rama fonética y textual.....	41
Tabla 12. Fonemas con mayor tasa de sustitución.....	44
Tabla 13. Pares de sustitución fonémica más frecuentes.....	44
Tabla 14. Ejemplos cualitativos de errores en la variante fonética.	46
Tabla 15. Ejemplos cualitativos de errores en la rama textual.	50
Tabla 16. Ejemplos de mejora sustancial debida al rescoring lingüístico en la rama textual.....	51
Tabla 17. Ejemplos en los que el rescoring lingüístico empeora la salida final en la rama textual.	51
Tabla 18. Ejemplos de audio sintetizado mediante Coqui TTS a partir de predicciones de la variante fonética.	53
Tabla 19. Descripción de los campos principales del conjunto de datos.	62

1. Introducció

1.1. Contexto y justificación del Trabajo

Personas con esclerosis lateral amiotrófica (ELA) o con lesiones en el tronco encefálico pueden sufrir parálisis del tracto vocal, lo que puede provocar disartria severa o incluso anartia, lo que limita o impide el habla inteligible y reduce de forma drástica su capacidad de comunicación. En estos casos, la pérdida del habla tiene un impacto directo en autonomía y participación social, y las tecnologías de comunicación aumentativa tradicionales suelen ser lentas y dependientes del control muscular residual. [1,2,3]

En este contexto, las interfaces cerebro-computador (BCI) buscan restaurar la comunicación al traducir señales neurológicas en comandos útiles en tiempo real, proporcionando un canal alternativo cuando las vías neuromusculares están deterioradas o son insuficientes. Sin embargo, muchas BCIs han estado limitadas por tasas de transferencia relativamente bajas y por requisitos de entrenamiento y estabilidad. [4]

Este TFM aborda un problema de reconocimiento automático del habla. En lugar de utilizar señales acústicas como entrada, el objetivo es decodificar texto a partir de actividad neuronal intracortical asociada al habla imaginada. Desde el punto de vista del aprendizaje automático, se trata de un problema supervisado de mapeo secuencia-a-secuencia, en el que una señal temporal de origen neural debe transformarse en una transcripción textual. La ausencia de un alineamiento temporal explícito entre la dinámica de la señal y las unidades lingüísticas sitúa el problema dentro del marco de tareas de secuencia con longitudes variables, similares a las que se plantean en reconocimiento automático del habla, aunque en este caso la entrada no es una señal acústica, sino actividad neurofisiológica. [1,2]

La importancia de este problema no solo radica en su interés científico y técnico, sino también en su potencial aplicación en sistemas de comunicación asistida para personas con pérdida severa del habla.

1.2. Descripción general

El TFM consistirá en diseñar, implementar y evaluar un sistema “brain-to-text” capaz de transformar actividad neuronal intracortical en transcripciones de texto a nivel de frase.

De forma general, el trabajo se enmarca en la línea de las neuroprótesis de comunicación y adopta un planteamiento inspirado en los sistemas de reconocimiento automático del habla, con la diferencia de que la señal de entrada no es acústica, sino neurofisiológica. En este

contexto, el sistema deberá aprender a extraer información lingüística a partir de la actividad neuronal y convertirla en texto escrito de forma automática. [1,2]

Los trabajos recientes en este ámbito muestran que una estrategia eficaz consiste en estructurar el problema en varias etapas, separando la decodificación de la señal neuronal de la reconstrucción lingüística final. Este enfoque permite abordar la complejidad temporal de la señal y facilita la generación de frases completas a partir de representaciones intermedias más manejables. [1,2]

La intención no es únicamente entrenar un modelo aislado, sino desarrollar un sistema reproducible y ampliable, con una línea base verificable y con margen para introducir y evaluar mejoras de forma controlada.

1.3. Motivación personal

La motivación de este TFM surge del interés por aplicar técnicas de inteligencia artificial a un problema con un impacto potencial directo en la calidad de vida de las personas. El ámbito de las interfaces cerebro-computador resulta especialmente interesante porque combina retos técnicos exigentes con una aplicación de alto valor social.

Desde el punto de vista académico, el trabajo permite abordar un problema secuencia-a-secuencia no convencional, cercano al reconocimiento automático del habla, pero basado en señales neuronales en lugar de audio.

1.4. Impacto en sostenibilidad, ético-social y de diversidad

Sostenibilidad:

El entrenamiento de modelos de aprendizaje implica un coste energético asociado al uso de recursos computacionales. Para reducirlo, en este trabajo se prioriza una experimentación eficiente mediante pruebas iniciales con subconjuntos de datos o configuraciones reducidas, uso de "early stopping", limitación del número de experimentos en la optimización de hiperparámetros y reutilización de artefactos mediante "checkpoints" y cachés. Además, se documentan los recursos empleados en los experimentos principales, incluyendo tiempo de cómputo, hardware utilizado y duración aproximada de los entrenamientos.

Ético-Social y responsabilidad:

La actividad neuronal constituye un tipo de dato altamente sensible. Aunque el conjunto de datos utilizado es público y anonimizado, el trabajo adopta una postura de minimización y uso finalista, el sistema se orienta exclusivamente a la decodificación del habla imaginada, evitando inferencias no necesarias para la tarea. Se considera además la importancia del

consentimiento informado, la gobernanza de los datos, la seguridad y los riesgos asociados a un posible uso indebido en escenarios clínicos o asistenciales.

Desde una perspectiva social, los sistemas de decodificación neuronal del habla pueden tener un impacto relevante en la autonomía de personas con pérdida severa de comunicación. Recuperar un canal más natural, fluido y menos dependiente de interfaces lentas o de terceros podría favorecer la toma de decisiones, la interacción social y la participación en la vida cotidiana. Por esto, el valor del sistema no debe evaluarse solo por su rendimiento técnico, sino también por su contribución potencial a la calidad de vida.

Diversidad y derechos humanos:

El conjunto de datos procede de un único participante, lo que limita la validez externa del modelo. Por lo que se debe discutir la necesidad de estudiar su generalización a otras personas y contextos clínicos, teniendo en cuenta la variabilidad interindividual, las diferencias en patrones neuronales, la progresión de la enfermedad o la fatiga. También se considera la accesibilidad del sistema, que debería funcionar en condiciones realistas y evitar depender excesivamente de las características particulares del sujeto registrado. Finalmente, se incluye una reflexión sobre su impacto en los derechos de privacidad, autonomía y control sobre el uso de las señales neuronales.

1.5. Objetivos

Objetivos generales:

El objetivo central de este Trabajo Fin de Máster es desarrollar un sistema reproducible de decodificación del habla ("brain-to-text") a partir de registros de actividad neuronal intracortical obtenidos durante procesos de producción de lenguaje. El propósito es diseñar, implementar y evaluar un modelo capaz de transformar señales neuronales en transcripciones textuales, optimizando su rendimiento mediante técnicas de aprendizaje profundo y un protocolo experimental riguroso basado en la métrica Word Error Rate (WER).

Objetivos específicos:

Para alcanzar este objetivo general, se plantean los siguientes objetivos específicos:

OE1. Análisis y caracterización del conjunto de datos

Analizar en profundidad el conjunto de datos empleado, estudiando su estructura, distribución de ensayos, variabilidad temporal y características de las señales neuronales, con el fin de identificar limitaciones, posibles sesgos y condicionantes experimentales relevantes para el diseño del sistema.

OE2. Construcción de un pipeline reproducible de entrenamiento y evaluación

Desarrollar un pipeline completo y reproducible que incluya carga de datos, preprocesado, entrenamiento y evaluación, definiendo una línea base estable y estableciendo un valor de

referencia de WER en validación bajo un protocolo experimental controlado, con particiones bien definidas, semillas y registro sistemático de experimentos.

OE3. Evaluación y mejora del modelado secuencia-a-secuencia

Explorar y comparar distintas alternativas de modelado para la decodificación neuronal a texto, partiendo de una línea base recurrente y analizando arquitecturas alternativas basadas en modelos de espacio de estados, así como distintas configuraciones de decodificación.

OE4. Integración y análisis del papel de los modelos de lenguaje

Estudiar la contribución de los modelos de lenguaje en la etapa de decodificación, comparando su efecto frente a variantes de decodificación directa sin etapa lingüística intermedia, y cuantificando su impacto sobre el rendimiento final del sistema.

OE5. Análisis de errores e interpretación de resultados

Realizar un análisis detallado de errores, incluyendo inserciones, borrados y sustituciones, para identificar patrones sistemáticos, limitaciones del modelo y factores que condicionan el rendimiento, proporcionando una interpretación técnica de las mejoras observadas respecto a la línea base.

Como extensión opcional del trabajo, se podrá integrar un módulo de síntesis de voz que permita generar salida hablada a partir del texto decodificado, documentando el funcionamiento del sistema completo de extremo a extremo.

1.6. Enfoque y método a seguir

1.6.1 Estrategia de investigación

Este Trabajo Fin de Máster se enmarca en una estrategia de investigación de Diseño y Creación ("Design and Creation"), ya que su objetivo no es solo estudiar un problema, sino también construir y evaluar una solución tecnológica concreta. En este caso, dicha solución consiste en un sistema de decodificación "brain-to-text" capaz de transformar señales neuronales asociadas a procesos de producción del lenguaje en transcripciones textuales.

Este enfoque es adecuado porque permite generar conocimiento técnico a partir del diseño, la implementación y la validación experimental del sistema. La contribución del trabajo no se limita, por tanto, a obtener una implementación funcional, sino que incluye también la comparación controlada entre distintas alternativas de modelado, la evaluación de su rendimiento y el análisis de los factores que influyen en su comportamiento.

Aunque parte del flujo de trabajo comparte elementos con metodologías de ciencia de datos como CRISP-DM, en este TFM estas se emplean únicamente como referencia organizativa. El enfoque principal del trabajo se basa en el desarrollo iterativo de un sistema reproducible,

su mejora progresiva y su validación cuantitativa mediante métricas objetivas, principalmente el "Word Error Rate" (WER).

1.6.2 Fases del desarrollo

Fase 1. Preparación y análisis del conjunto de datos:

En esta fase se estudia la estructura del conjunto de datos, la distribución de ensayos y las características de las señales neuronales y de las transcripciones objetivo. Además, se realiza la preparación inicial de los datos para entrenamiento y validación.

Fase 2. Desarrollo de una línea base reproducible:

Se construye un pipeline reproducible de carga de datos, preprocesado, entrenamiento y evaluación, sobre el que se define una línea base inicial y se fijan las condiciones experimentales básicas.

Fase 3. Experimentación y mejora del modelo:

A partir de la línea base, se exploran distintas alternativas de modelado y decodificación con el objetivo de comparar arquitecturas y cuantificar el efecto de cada decisión de diseño.

Fase 4. Validación y análisis de resultados:

Se evalúan las distintas variantes mediante métricas objetivas y se realiza un análisis de errores para identificar patrones sistemáticos y limitaciones del sistema.

Fase 5. Documentación y cierre del trabajo:

Finalmente, se documentan el sistema, los experimentos y los resultados obtenidos, incluyendo la memoria del TFM y la organización del código y de los artefactos experimentales.

1.7. Planificación

1.7.1 Tareas

La planificación del trabajo se estructuró a partir de las fases de desarrollo descritas en el apartado anterior. En primer lugar, se abordaron la revisión bibliográfica, la delimitación del alcance y el análisis inicial del conjunto de datos. A continuación, se preparó el entorno experimental y se desarrolló una línea base reproducible que sirviera como referencia para la comparación de variantes. Sobre esta base, se llevó a cabo la fase principal de experimentación, seguida de la validación de resultados, el análisis de errores y la redacción final de la memoria.

La Tabla 1 resume las principales tareas, su relación con los objetivos del proyecto y una duración estimada.

Tabla 1. Planificación de tareas del TFM y relación con objetivos

Tarea	Descripción	Relación objetivos	Duración aproximada
T1	Revisión bibliográfica, definición del alcance y problema de investigación.	OE1, OE3, OE4	4 sem
T2	Análisis del conjunto de datos y preparación del entorno reproducible de trabajo.	OE1, OE2	3 sem
T3	Desarrollo del pipeline base de carga preprocesado, entrenamiento y evaluación.	OE2, OE3	3 sem
T4	Construcción de la línea base reproducible y obtención del WER de referencia.	OE3	1 sem
T5	Experimentación con variantes de modelado y comparación controlada de resultados.	OE4	3 sem
T6	Evaluación del papel de los modelos de lenguaje y de variantes de decodificación directa	OE4	1 sem
T7	Validación final, análisis de errores y selección del modelo más adecuado.	OE5	1 sem
T8	Documentación técnica, redacción final de la memoria y preparación de la defensa	Entregables	4 sem

1.7.2 Calendario

La distribución temporal del trabajo se organizó combinando actividades de análisis, desarrollo experimental, validación y documentación final, teniendo en cuenta el posible solapamiento entre algunas de ellas. La Figura 1 muestra el cronograma general del TFM mediante un diagrama de Gantt.




Figura 1 Cronograma general del TFM. Fuente: elaboración propia.

1.7.3 Hitos

La evolución del trabajo se estructuró en varios hitos principales asociados a las fases del proyecto. El primer hito correspondió a la definición inicial del alcance, objetivos, planificación y riesgos. El segundo consistió en completar el estado del arte y disponer de una línea base reproducible con un resultado de referencia. El tercer hito se centró en la implementación y evaluación de las principales variantes de modelado y decodificación. El cuarto correspondió a la elaboración de una versión preliminar de la memoria junto con la selección del modelo

final y el análisis de errores. Finalmente, los últimos hitos se asociaron al cierre de la memoria, la preparación de la presentación y la defensa final del trabajo.

1.7.4 Análisis de riesgos

El desarrollo del TFM presentaba varios riesgos potenciales relacionados con el alcance del proyecto, las limitaciones computacionales, la generalización de los modelos y la reproducibilidad experimental. Con el objetivo de anticiparlos y reducir su impacto, se definieron medidas de mitigación específicas, resumidas en la Tabla 2.

Tabla 2. Principales riesgos del TFM y medidas de mitigación

Riesgo	Nivel	Descripción	Mitigación
Alcance excesivo del proyecto	Alto	El trabajo podría crecer en complejidad si se exploran demasiadas variantes de modelado o extensiones no esenciales	Limitar la experimentación principal a un número acotado de variantes y priorizar la comparación de modelos y el análisis de resultados
Limitaciones computacionales y tiempo de entrenamiento elevado	Medio	El coste de entrenamiento puede ralentizar el desarrollo experimental	Utilizar "early stopping", checkpoints y configuraciones reducidas para pruebas preliminares
Sobreajuste o baja generalización	Alto	El sistema puede adaptarse en exceso al conjunto de datos disponible	Mantener validación controlada, aplicar regularización y analizar los resultados con cautela
Reproducibilidad insuficiente	Alto	La falta de control sobre semillas, configuraciones o versiones de código podría dificultar la réplica de resultado	Definir un protocolo reproducible con semillas fijas, versionado de configuraciones y registro de experimentos
Sobrecarga de tiempo en la redacción de la memoria	Medio	Dejar la redacción para la fase final puede afectar a la calidad del documento	Avanzar la redacción de forma progresiva en paralelo al desarrollo técnico
La extensión de síntesis de voz compromete el objetivo principal	Bajo	La incorporación de una salida hablada puede consumir tiempo y recursos del sistema principal	Tratar la síntesis de voz como una extensión opcional

1.8. Resultados esperados

Como resultado principal del TFM, se espera desarrollar un sistema reproducible de decodificación "brain-to-text", implementado mediante un pipeline completo que integre carga de datos, preprocesado, entrenamiento, inferencia y evaluación. Este sistema deberá

permitir la comparación controlada entre una línea base reproducible y las variantes de modelado exploradas.

Asociado a este desarrollo, se dispondrá de un repositorio con el código del sistema, organizado y documentado para facilitar la trazabilidad del proceso experimental y la replicación de los resultados. Además, se conservarán los principales artefactos experimentales, como configuraciones, métricas y checkpoints de los modelos más relevantes.

Desde el punto de vista experimental, se espera obtener un conjunto de resultados cuantitativos comparables, evaluados bajo un mismo protocolo y reportados principalmente mediante la métrica WER, junto con el análisis de errores correspondiente. Además, se dispondrá de un prototipo funcional capaz de ejecutar el flujo principal de decodificación desde la señal de entrada hasta la generación de transcripciones textuales o voz sintetizada.

Finalmente, como resultados académicos, se obtendrán la memoria del TFM, la presentación audiovisual y el resto de la documentación requerida para la evaluación y defensa del trabajo.

1.9 Estructura de la memoria

La memoria se organiza en siete capítulos: El capítulo 1 introduce el contexto del trabajo, la motivación, los objetivos, la metodología seguida, la planificación y los resultados esperados. El capítulo 2 revisa el estado del arte sobre interfaces cerebro-computador, neuroprótesis del habla, paradigmas "brain-to-text" y técnicas de evaluación. El capítulo 3 describe el diseño e implementación del sistema desarrollado, incluyendo el conjunto de datos, el preprocesado, las arquitecturas evaluadas, la decodificación lingüística y el módulo de síntesis de voz. El capítulo 4 presenta la evaluación experimental, los resultados obtenidos, el análisis de errores y la discusión global. Finalmente, el capítulo 5 recoge las conclusiones, limitaciones y líneas de trabajo futuras, mientras que los capítulos 6 y 7 incluyen la bibliografía y los anexos.

2. Estado del arte

2.1. Problema clínico y necesidad de comunicación asistida

La pérdida de la capacidad comunicativa constituye una de las consecuencias más incapacitantes de diversos trastornos neurológicos que afectan al control del tracto vocal. Enfermedades como la esclerosis lateral amiotrófica (ELA) o las lesiones del tronco encefálico pueden provocar disartria severa o anartia, limitando o anulando la capacidad de habla y reduciendo de forma importante la autonomía y la calidad de vida [1,2]. Esto no solo compromete la expresión oral, sino que también se asocia con aislamiento y depresión hasta el punto de que la comunicación pasa a convertirse en una prioridad clínica en personas con parálisis y trastornos motores del habla [1,2].

Frente a la velocidad y naturalidad del habla conversacional, las tecnologías convencionales de comunicación alternativa suelen ofrecer interacciones más lentas y dependen con frecuencia de algún control muscular residual, como el movimiento ocular o cefálico [1,2]. Además, muchas BCIs (del inglés, “Brain-Computer Interface”) clásicas han estado limitadas por tasas de transferencia de información reducidas y por una interacción poco natural [3,4]. En este contexto, las neuroprótesis del habla surgen como una alternativa prometedora, al decodificar directamente la actividad cortical asociada al habla imaginada para transformarla en texto o voz sintetizada. Su interés clínico radica en que, incluso cuando la salida motora está gravemente deteriorada, parte de las representaciones corticales relacionadas con la articulación puede permanecer preservada [1].

Los avances recientes muestran que esta línea ya no es solo una posibilidad teórica. Moses y otros demostraron la decodificación de frases en tiempo real en una persona con anartia [5], y Card y otros mostraron que una neuroprótesis intracortical podía restaurar una comunicación conversacional de aproximadamente 32 palabras por minuto en un paciente con ELA y disartria severa [2]. En conjunto, estos resultados confirman la relevancia clínica y tecnológica del campo, aunque siguen existiendo márgenes importantes de mejora en precisión, robustez y generalización.

2.2. De las BCIs generales a neuroprótesis del habla

Las BCIs surgieron como una alternativa a los canales neuromusculares convencionales para personas con trastornos motores graves, permitiendo traducir señales neurofisiológicas en comandos de comunicación o control [4]. En sus primeras etapas, el campo se centró sobre todo en restaurar funciones básicas mediante selección de letras, control de cursores o escritura asistida, generalmente con sistemas no invasivos basados en EEG, P300, ritmos sensorimotrices o potenciales corticales lentos [4,6]. Aunque estas aproximaciones

demonstraron la viabilidad del paradigma, su rendimiento seguía siendo limitado en velocidad, estabilidad y naturalidad comunicativa [4,6]. La Figura 2 muestra de forma esquemática el funcionamiento de una BCI basada en P300, representativa de esta primera etapa de interfaces orientadas principalmente a tareas de selección y comunicación asistida básica.




Figura 2. Esquema de funcionamiento de una BCI basada en P300. Fuente: adaptado de *Overlapped Partitioning for Ensemble Classifiers of P300-Based Brain-Computer Interfaces*, PLOS One, 2014. Licencia CC BY 4.0.

En estos sistemas, la comunicación se plantea normalmente como una selección discreta de símbolos o comandos, por ejemplo mediante la detección de respuestas P300 ante estímulos visuales o mediante el control voluntario de ritmos cerebrales. Aunque este enfoque permitió demostrar que era posible establecer un canal de comunicación independiente de la vía muscular, la interacción seguía siendo indirecta, el usuario no producía habla ni texto continuo, sino que debía seleccionar elementos de forma secuencial. Esta diferencia explica por qué, pese a su importancia histórica, las BCIs clásicas no resolvían completamente la necesidad de una comunicación rápida, flexible y cercana al habla natural [3,4,6].

La transición hacia las neuroprótesis del habla se produjo cuando el problema dejó de formularse como una tarea de selección secuencial para pasar a abordarse como una decodificación directa de la actividad relacionada con la producción del habla. Este cambio respondió, en parte, a que muchas de las soluciones previas resultaban insuficientes para personas con parálisis severa o con pérdida casi completa del control de los articuladores [3]. En este contexto, una prótesis del habla basada directamente en actividad cortical apareció como una vía prometedora para recuperar formas de comunicación más rápidas y naturales [3].

La evolución del campo desde las BCIs generales hasta las neuroprótesis del habla actuales se resume en la Figura 3, donde se recogen algunos de los principales hitos del área, desde las primeras demostraciones de viabilidad hasta sistemas capaces de decodificar texto, sintetizar voz e integrar componentes multimodales [1].




Figura 3. Hitos principales del desarrollo de las neuroprótesis del habla. Fuente: adaptado de Silva y otros [1].

Este cambio ha sido posible gracias a la convergencia entre una mejor comprensión neurocientífica del control cortical del habla y el desarrollo de métodos de aprendizaje profundo capaces de modelar la relación entre actividad cerebral y unidades lingüísticas [7]. En consecuencia, las neuroprótesis del habla pueden entenderse como una especialización de las BCIs clásicas orientada específicamente a restaurar la comunicación oral de forma más natural, rápida y expresiva. Por ello, este trabajo se sitúa no en el ámbito general de las BCIs de control o deletreo, sino en la línea más reciente de sistemas "brain-to-text" y neuroprótesis del habla [1,7].

2.3. Bases neurofuncionales de la producción y decodificación del habla

La producción y percepción del habla dependen de una red distribuida en regiones frontales, temporales y parietales, y no de un único centro del lenguaje. Una de las propuestas más influyentes para describir esta organización es el modelo de doble vía de Hickok y Poeppel, según el cual existe una vía ventral implicada en la transformación de sonido en significado y una vía dorsal encargada de mapear señales del habla hacia redes articulatorias del lóbulo frontal [8]. Esta distinción es especialmente relevante para las neuroprótesis del habla, ya

que sitúa la decodificación en la interfaz entre información auditiva, fonológica y motora. La Figura 4 muestra de forma esquemática algunas de las principales regiones corticales implicadas en el procesamiento del lenguaje [9]




Figura 4. Principales regiones corticales implicadas en el procesamiento del lenguaje. Fuente: adaptado de Friederici AD. "The Brain Basis of Language Processing: From Structure to Function". *Physiol Rev.* 2011;91(4). doi:10.1152/physrev.00006.2011.

Dentro de esta organización, se ha destacado la importancia de la corteza perisilviana izquierda y, en particular, de las conexiones entre la corteza temporal superior, las regiones premotoras y la corteza frontal inferior. Hickok y Poeppel describen un circuito dorsal sensoriomotor en el que la región *Spt* actúa como una interfaz entre la codificación sensorial del habla y el sistema motor articulatorio [8]. En su revisión, los autores sitúan esta región en la fisura de Silvio, en el límite parieto-temporal, y señalan además que se localiza dentro del *planum temporale* [8]. Conviene especificar que en el artículo *Spt* se utiliza como una etiqueta anatómico-funcional, pero no se expande explícitamente la abreviatura [8].

De forma complementaria, Pulvermüller plantea que el lenguaje hablado se apoya en circuitos de acción-percepción distribuidos entre la corteza frontal y temporal, reforzados por aprendizaje asociativo y por una conectividad dorsal a través del fascículo arqueado [10]. Desde esta perspectiva, producción y percepción del habla no son procesos separados, sino funciones que se sustentan por circuitos fuertemente solapados que enlazan información auditiva, articulatoria y lingüística [10].

En cuanto al control motor del habla, la revisión de Silva y otros destaca el papel de la corteza sensorimotora ventral y del giro precentral medio en el control de los articuladores del tracto vocal [1]. Estas regiones presentan una organización relacionada con distintos articuladores

y codifican trayectorias cinemáticas del habla, mientras que el giro temporal superior contribuye al procesamiento de rasgos acústicos relevantes [1]. En conjunto, estas revisiones apoyan la idea de que las señales corticales asociadas al habla contienen información articuladora, acústica y lingüística parcialmente solapada, lo que justifica intentar decodificarlas hacia unidades subléxicas o textuales [1].

Estas bases neurofuncionales ayudan también a explicar por qué la decodificación del habla a partir de actividad intracortical es factible. Wilson y otros mostraron que señales registradas mediante *arrays* intracorticales permitían discriminar fonemas del inglés con rendimiento superior al azar, y que ese rendimiento mejoraba al explotar la estructura temporal de la señal [11]. Aunque la localización estudiada no era la óptima para una neuroprótesis del habla, sus resultados refuerzan la idea de que la corteza motora contiene información suficientemente rica sobre la producción fonética y de que la decodificación puede beneficiarse de modelos secuenciales capaces de capturar dinámicas temporales [1,11].

2.4. Tipos de señal y grado de invasividad

La elección de la señal neuronal es una decisión central en cualquier BCI orientada a la comunicación, ya que condiciona la seguridad clínica del sistema, su resolución espaciotemporal y la estabilidad del registro a largo plazo. En las neuroprótesis del habla se da un compromiso entre invasividad y calidad de la información. Las técnicas menos invasivas son más seguras y accesibles, pero ofrecen menor especificidad espacial, mientras que las técnicas invasivas permiten acceder a señales más ricas a costa de mayores exigencias clínicas [1,3]. La Figura 5 resume de forma esquemática las diferencias entre EEG, ECoG y registros intracorticales.




Figura 5. Comparación esquemática entre EEG, ECoG y registros intracorticales. Fuente: adaptado de Alahi MEE y otros, *Recent advancement of electrocorticography (ECoG) electrodes for chronic neural recording/stimulation*. *Mater Today Commun.* 2021. doi:10.1016/j.mtcomm.2021.102853 [12]

Las técnicas no invasivas, y en particular el EEG, han sido fundamentales en las BCIs clásicas de comunicación por no requerir cirugía y permitir un uso relativamente sencillo en

pacientes con parálisis [4,6]. Sin embargo, su resolución espacial es limitada, ya que cada sensor recoge actividad agregada de regiones más amplias del cerebro, lo que dificulta escalar hacia tareas complejas de decodificación del habla [1,3,6]. Por ello, aunque el EEG sigue siendo relevante como antecedente histórico y como opción de baja invasividad, no ha impulsado los principales avances recientes en sistemas "brain-to-text" [1].

En el ámbito de la decodificación del habla, esta limitación dificulta escalar hacia vocabularios amplios o segmentos como frases completas pese a que estas técnicas suelen preferirse por su nivel de seguridad [1]. Por ello, aunque el EEG resulta muy relevante como antecedente histórico y como opción de baja invasividad, no ha sido la modalidad que ha impulsado los mayores avances recientes en los sistemas "brain-to-text" [1,4,6].

Como punto intermedio se sitúa la electrocorticografía o ECoG, en la que los electrodos se colocan sobre la superficie cortical sin penetrar el tejido cerebral. Esta técnica ofrece mayor ancho de banda y mejor relación señal-ruido que el EEG, y permite registrar información útil sobre representaciones acústicas y articulatorias del habla [1,3]. Además, su capacidad para cubrir áreas corticales extensas implicadas en la producción del habla la convierte en una candidata sólida para aplicaciones clínicas [1]. Estudios recientes, como el de Metzger y otros, han utilizado ECoG para decodificar texto, sonido y movimientos orofaciales [17].

En el extremo de mayor invasividad se encuentran los registros intracorticales mediante *microelectrode arrays* o MEA, que penetran el córtex y permiten medir actividad de neuronas individuales o pequeños grupos neuronales [1]. Esta modalidad ofrece la mayor resolución espacial y temporal y ha sido decisiva en algunos de los avances más recientes en decodificación del habla [1,14]. Trabajos como los de Willett y otros o Card y otros muestran que este tipo de señal puede sostener sistemas "brain-to-text" de vocabulario amplio y velocidades de comunicación elevadas [2,14].

No obstante, esta ventaja en resolución conlleva limitaciones prácticas y clínicas. Los *arrays* intracorticales cubren regiones más pequeñas que la ECoG y plantean mayores exigencias de biocompatibilidad, estabilidad y mantenimiento a largo plazo [1]. Además, su rendimiento puede degradarse con el tiempo debido a procesos inflamatorios y de encapsulamiento tisular alrededor del implante. Como señalan Wilson y otros, las señales registradas con microelectrodos y con ECoG no son equivalentes, ya que difieren en localización física, tamaño del electrodo, rango frecuencial y fisiología de la señal [11].

2.5. Paradigmas de salida en neuroprótesis de comunicación

Las neuroprótesis de comunicación pueden clasificarse según el tipo de salida que proporcionan al usuario. En la literatura reciente, esta salida ya no se limita al texto en pantalla, sino que puede adoptar la forma de deletreo asistido, texto continuo, voz sintetizada o salidas multimodales que integran varios canales de comunicación [1]. Cada paradigma

implica compromisos distintos en términos de naturalidad comunicativa, velocidad, complejidad algorítmica y criterios de evaluación. La Figura 6 resume de forma esquemática los principales paradigmas de salida en neuroprótesis de comunicación.




Figura 6. Esquema general de los paradigmas de salida en neuroprótesis de comunicación. Fuente: elaboración propia.

El primer paradigma corresponde a los sistemas basados en deletreo, en los que la señal neuronal no se transforma directamente en palabras o frases completas, sino en letras o unidades equivalentes que el usuario concatena para formar mensajes. Aunque este enfoque es menos natural que el habla continua, facilita la generalización a vocabularios amplios. Un ejemplo representativo es el trabajo de Metzger y otros, en el que un participante con parálisis severa y anartia empleó un sistema de deletreo en tiempo real basado en el alfabeto fonético de la OTAN [13].

El segundo paradigma es el "brain-to-text", en el que la salida final del sistema es texto escrito generado a partir de actividad cortical asociada al habla imaginada. Este ha sido el paradigma que más rápidamente ha progresado en los últimos años, en parte porque permite combinar la decodificación neuronal con modelos de lenguaje que corrigen o completan hipótesis parciales. Trabajos como los de Moses, Willett y Card muestran que este enfoque puede alcanzar velocidades de comunicación cada vez más cercanas a una interacción funcional [2,5,14]. Por ello, actualmente constituye la opción más madura para restaurar comunicación en personas con parálisis del tracto vocal.

El tercer paradigma es el "brain-to-voice" o "brain-to-speech", en el que la salida del sistema es habla sintetizada y no solo texto. Su objetivo es recuperar no solo el contenido léxico, sino también propiedades de la voz humana, como la prosodia o la retroalimentación auditiva inmediata. En esta línea, Anumanchipalli y otros propusieron un sistema en dos etapas que infería representaciones articulatorias antes de sintetizar voz audible [15]. Más recientemente, Wairagkar y otros presentaron una neuroprótesis intracortical capaz de sintetizar voz con latencias muy bajas y con cierta modulación paralingüística en tiempo real

[16]. Aunque este paradigma apunta a una restauración comunicativa más natural, requiere un modelado más complejo que los sistemas basados únicamente en texto [15,16].

Finalmente, empieza a consolidarse un paradigma multimodal, en el que una misma neuroprótesis genera varias salidas de forma simultánea, como texto, audio sintetizado o movimientos orofaciales de un avatar. Este enfoque busca restaurar no solo el contenido verbal, sino también componentes expresivos de la comunicación. En esta línea, Metzger y otros desarrollaron una neuroprótesis basada en ECoG de alta densidad capaz de decodificar texto, sonido y movimientos orofaciales verbales y no verbales, incluyendo el control de un avatar facial personalizado [17].

En conjunto, el campo ha evolucionado desde salidas discretas basadas en deletreo hacia sistemas capaces de producir texto continuo, voz sintetizada y representaciones audiovisuales del habla. Estos paradigmas no son excluyentes, sino que responden a distintos compromisos entre robustez, naturalidad y complejidad. Mientras que el deletreo prioriza control y generalización, el enfoque "brain-to-text" representa actualmente la opción más consolidada para restaurar comunicación funcional, y las aproximaciones "brain-to-speech" y multimodales apuntan a una recuperación más completa de la expresividad comunicativa [1,15,16,17].

2.6. Pipeline técnico de sistemas brain-to-text

2.6.1 Gestión de secuencias de longitud variable y ausencia de alineamiento explícito

Uno de los rasgos técnicos que distingue los sistemas "brain-to-text" es que el problema debe formularse como una tarea secuencia-a-secuencia. La entrada está compuesta por series temporales multicanal de actividad neuronal, mientras que la salida es una secuencia lingüística, normalmente fonémica o textual, cuya longitud puede variar entre ensayos. Aunque esta estructura recuerda a la de un sistema clásico de reconocimiento automático del habla, la sustitución de la señal acústica por señal neuronal introduce dificultades adicionales, como una mayor dimensionalidad, más ruido y conjuntos de entrenamiento mucho más reducidos [18,19].

En este contexto, uno de los principales retos es la ausencia de un alineamiento temporal explícito entre la señal de entrada y la secuencia objetivo. Li y otros formulan este escenario como un mapeo $f: X \rightarrow Z$ desde una matriz de actividad neural $X \in \mathbb{R}^{T \times D}$ hacia una secuencia fonémica objetivo $Z \in Z^{T'}$ donde D es el número de características neurales y T el número de intervalos temporales, mientras que la secuencia objetivo tiene longitud T' , generalmente menor que T , ya que un mismo fonema puede extenderse varios pasos temporales [18]. Estos autores, subrayan además que no existe alineamiento temporal de

referencia entre X y Z , y tanto T como T' varían entre ensayos, precisamente por la naturaleza del habla imaginada [18].

La estructura general de este tipo de sistemas puede entenderse como un pipeline de varias etapas, en el que la actividad neural se transforma progresivamente en representaciones intermedias y finalmente en texto, tal como se muestra en la figura 7.




Figura 7 Visión general del pipeline de decodificación brain-to-text. Fuente: adaptado de Li y otros [18].

Desde un punto de vista práctico, esta estructura obliga a utilizar estrategias de preparación de datos adecuadas para el entrenamiento por lotes, como relleno de secuencias, máscaras y normalización entre canales. No obstante, estas técnicas no resuelven por sí solas el problema de comparar una secuencia de predicciones temporales con una secuencia objetivo no alineada. Por ello, en este dominio se ha consolidado el uso de funciones de pérdida diseñadas para secuencias no segmentadas, especialmente la *connectionist temporal classification* o CTC [18,19].

2.6.2 Modelos secuencia-a-secuencia aplicados al problema: RNN, atención y Transformers

Sobre este contexto secuencial, se han explorado distintas familias de modelos para transformar la actividad neuronal en representaciones lingüísticas. Históricamente, las arquitecturas recurrentes han ocupado una posición central. La revisión de Silva y otros recuerda que algunos de los primeros avances relevantes hacia vocabularios y frases más amplios se apoyaron en marcos recurrentes de tipo *encoder-decoder*, capaces de capturar patrones temporales de la actividad neuronal durante la producción del habla [1].

Dentro de estas arquitecturas, las variantes basadas en RNN y, en particular, en GRU, siguen siendo especialmente relevantes en sistemas "brain-to-text". Li y otros señalan que tanto trabajos previos como sus propios experimentos encuentran un rendimiento superior de GRU frente a LSTM y Transformers en el benchmark considerado [18]. En la misma línea, el benchmark reciente concluye que ha resultado más difícil mejorar la arquitectura base que optimizar su entrenamiento, de modo que los mayores avances procedieron del ajuste de la

línea base recurrente y del uso de *ensembles* con modelos de lenguaje, más que de su sustitución por arquitecturas alternativas [19].

No obstante, los mecanismos de atención y los Transformers siguen siendo candidatos naturales en esta tarea. En procesamiento del lenguaje y del habla, estos modelos permiten incorporar información contextual de posiciones alejadas de la secuencia mediante mecanismos de *self-attention*, lo que resulta atractivo para señales neuronales distribuidas en el tiempo [20]. Sin embargo, las evidencias recientes no muestran una ventaja empírica de los Transformers como decodificadores neurales principales, en parte porque los conjuntos de datos disponibles siguen siendo relativamente limitados, lo que favorece que los modelos recurrentes continúen siendo una opción especialmente sólida [18].

2.6.3 Decodificación neuronal en dos etapas: de actividad neural a fonemas y de fonemas a texto

Más allá de la arquitectura concreta del decodificador neural, muchos sistemas actuales comparten una decisión de diseño central. No traducen directamente la señal neuronal a texto final, sino que dividen el problema en dos etapas. En la primera, un modelo temporal transforma la actividad neuronal en probabilidades de fonemas u otras unidades subléxicas; en la segunda, un modelo de lenguaje convierte esas hipótesis en palabras y frases plausibles [1,2,18].

Esta estrategia puede observarse, por ejemplo, en el trabajo de Card y otros, donde la actividad cortical se utiliza para predecir fonemas y, posteriormente, varias etapas de modelo de lenguaje permiten reconstruir la frase final más probable [2]. La Figura 8 resume este esquema general de decodificación en dos etapas.




Figura 8. Esquema de decodificación en dos etapas desde actividad neural a fonemas y de fonemas a texto. Fuente: adaptado de Card y otros, *An accurate and rapidly calibrating speech neuroprosthesis*. *N Engl J Med*. 2024;391:609-618.[2]

La revisión de Silva y otros justifica esta decisión desde una perspectiva más general: para escalar más allá de vocabularios cerrados o frases prefijadas, resulta útil decodificar primero unidades subléxicas y apoyarse después en modelos de lenguaje que capturen regularidades estadísticas entre ellas para reconstruir la frase completa [1]. Esta solución favorece la generalización, ya que un conjunto reducido de fonemas puede recombinarse para formar un vocabulario amplio, algo especialmente relevante cuando la cantidad de datos es limitada [1,18].

En esta línea, Li y otros proponen sustituir el objetivo intermedio de fonema aislado por difonemas, es decir, transiciones entre fonemas adyacentes que capturan mejor la dependencia contextual de la señal [18]. Aunque estas unidades aumentan la complejidad del aprendizaje, sus experimentos muestran que pueden mejorar la decodificación fonémica y reducir de forma notable el WER cuando se combinan con modelos de lenguaje y estrategias de ensemble [18].

2.7. Evaluación

La evaluación de las neuroprótesis "brain-to-text" no debe medir solo si el sistema genera texto, sino con qué fidelidad reproduce el mensaje que la persona pretendía comunicar. La métrica más utilizada en este contexto es el Word Error Rate (WER), que cuantifica el número de inserciones, borrados y sustituciones necesarias para transformar la secuencia predicha en la secuencia de referencia [1,18]. Junto a ella, algunos estudios emplean métricas complementarias como el Phoneme Error Rate (PER) o el Character Error Rate (CER), útiles para distinguir si los errores se originan en la etapa de decodificación neural o en la reconstrucción lingüística posterior [1].

Además de la exactitud, también es importante considerar la velocidad efectiva de comunicación, normalmente expresada en palabras por minuto. Los trabajos más representativos del área combinan ambas perspectivas, ya que la utilidad práctica del sistema depende del equilibrio entre precisión y velocidad [2,5,14]. Así, un sistema muy preciso, pero lento puede resultar poco funcional, mientras que uno rápido con muchos errores pierde valor comunicativo.

Aunque el WER se considera la métrica de referencia, la literatura reciente insiste en la necesidad de contextualizar y normalizar los protocolos de evaluación para mejorar la comparabilidad entre estudios. Silva y otros destacan que factores como la etiología del trastorno, el tipo de instrucción de habla, el tamaño del vocabulario, la modalidad de salida o el tipo de señal neuronal pueden modificar sustancialmente el significado de los resultados reportados [1].

2.8. Benchmarks, reproducibilidad y limitaciones

El progreso reciente de las neuroprótesis "brain-to-text" no se debe solo a la mejora de los modelos, sino también a la disponibilidad de benchmarks públicos y líneas base comparables. Aunque existen distintos conjuntos de datos para investigación en BCIs aplicadas a la comunicación, como KARA ONE, BCI2020 o UGR-MINDVOICE, muchos de ellos se basan en EEG no invasivo y, por tanto, presentan limitaciones de resolución espacial que dificultan escalar hacia vocabularios amplios o tareas de decodificación más complejas.

Entre los recursos más recientes, el benchmark Brain-to-Text '24 ha sido especialmente relevante al proponer una tarea común sobre un conjunto de validación oculto y una línea base reproducible. Esta línea base se apoya en un decodificador recurrente con pérdida CTC para mapear actividad neuronal a probabilidades fonémicas, seguido de una etapa de decodificación lingüística con un modelo 5-gram y rescoring. Los mejores resultados del benchmark se obtuvieron mediante mejoras incrementales sobre esta base, como *ensembles*, mejor ajuste del entrenamiento y objetivos contextuales como difonemas, mientras que los Transformers no mostraron una ventaja clara sobre la arquitectura recurrente [19]. En la misma línea, Li y otros mostraron que gran parte de la mejora provenía de combinar representaciones dependientes del contexto con estrategias de rescoring basadas en modelos de lenguaje, más que de sustituir completamente el modelo base [18,19].

Para contextualizar el rendimiento alcanzado por algunos trabajos representativos del área, la Tabla 3 resume varias métricas de referencia reportadas en la literatura reciente.

Tabla 3. Estudios y métricas de referencia en neuroprótesis "brain-to-text".

Estudio	Salida	Vocabulario	Métrica principal	Velocidad
Moses y otros, 2021	Brain-to-text	50 palabras	WER mediana 25,6% con modelo de lenguaje	15,2 palabras/min
Metzger y otros, 2022	Neuroprótesis basada en deletreo	1.152 palabras	CER mediana 6,13%	29,4 caracteres/min
Willett y otros, 2023	Brain-to-text	50 palabras y 125.000 palabras	WER 9,1% y 23,8%	62 palabras/min
Metzger y otros, 2023	Brain-to-text multimodal	50 frases AAC y 1.024 palabras	WER mediana 25%	78 palabras/min
Card y otros, 2024	Brain-to-text	50 palabras y 125.000 palabras	Accuracy 99,6% y 90,2%	32 palabras/min
Brain-to-text Benchmark '24	Benchmark reproducible	1.200 frases	Baseline 9,7% WER; mejor entrada 5,8% WER	No reportado
Li y otros, 2024	Método sobre el benchmark	Brain-to-text benchmark '24	PER 15,34%; WER 5,77%	No reportado

Como se observa en la Tabla 3, la comparación directa entre estudios se ha de interpretar con cautela, ya que el tamaño del vocabulario, tipo de salida y métricas reportadas difieren.

Aun así, la literatura reciente coincide en varias limitaciones importantes. Silva y otros destacan que muchos estudios en personas con parálisis se han realizado con muy pocos participantes, o incluso con un único participante, lo que dificulta la generalización de los resultados [1]. Además, los sistemas intracorticales siguen presentando retos de estabilidad de la señal y necesidad de recalibración, aunque ya existen estrategias orientadas a mitigar estos efectos [1].

2.9. Posicionamiento del TFM en el contexto actual

El estado actual del campo muestra que las neuroprótesis del habla han pasado de ser una demostración de viabilidad a constituir un área con resultados funcionalmente relevantes. En los últimos años se han desarrollado sistemas capaces de decodificar habla imaginada con vocabularios amplios y velocidades de comunicación cada vez más próximas a escenarios conversacionales naturales en personas con parálisis del tracto vocal [1,2]. Además, la aparición de benchmarks públicos y líneas base reproducibles ha desplazado el foco desde la prueba de concepto hacia la comparación sistemática de algoritmos y estrategias de entrenamiento [19].

No obstante, siguen existiendo limitaciones importantes, como el reducido número de participantes, la heterogeneidad en el tipo de señal, el tamaño del vocabulario y las condiciones de evaluación, lo que dificulta establecer comparaciones homogéneas entre estudios [1]. Además, el hecho de que muchas de las mejoras recientes provengan de optimizar el entrenamiento, la representación intermedia o la etapa de decodificación, más que de sustituir la arquitectura base, indica que sigue habiendo margen para nuevas contribuciones en este ámbito [18,19].

En este contexto, este TFM se sitúa como un trabajo acotado y orientado a la comparación experimental. Su objetivo no es desarrollar una neuroprótesis clínica completa, sino construir y evaluar un sistema reproducible de decodificación "brain-to-text" a partir de actividad neuronal, tomando como referencia una línea base comparable y analizando el efecto de distintas variantes arquitectónicas y de decodificación lingüística sobre el rendimiento final.

3. Diseño e implementación del sistema

En este capítulo se describen los detalles técnicos del sistema desarrollado. En primer lugar, se presenta una visión general del pipeline implementado y de sus principales componentes. A continuación, se detallan el entorno experimental, la preparación y preprocesado de los datos, las arquitecturas de decodificación evaluadas, las estrategias de inferencia y rescoring lingüístico, y la integración final del módulo de síntesis de voz.

3.1 Visión general del sistema

El sistema desarrollado transforma actividad neuronal intracortical asociada al habla imaginada en una salida comunicativa en forma de texto y, de manera complementaria, en voz sintetizada, tal como se ilustra en la Figura 9. La entrada está formada por secuencias temporales multicanal de señales neuronales y la salida principal es una transcripción textual a nivel de frase.




Figura 9. Pipeline general del sistema de decodificación neuronal a texto y voz. Fuente: elaboración propia.

La implementación se organiza como un pipeline modular que incluye la carga y preparación de datos, el preprocesado de la señal, el entrenamiento del decodificador neuronal, la inferencia y la generación de la transcripción final. Sobre esta estructura común se evalúan dos variantes de decodificación: una fonética, que predice unidades fonémicas intermedias

y las convierte posteriormente en texto mediante un modelo de lenguaje, y una textual, que decodifica directamente caracteres a partir de la señal neuronal.

Las dos variantes comparten la mayor parte de la infraestructura experimental y se diferencian principalmente en la representación objetivo y en la etapa de decodificación lingüística. Esta organización permite comparar el efecto de la representación de salida, el uso de modelos de lenguaje y la arquitectura del decodificador. Además, el trabajo incorpora aportaciones propias, como la adaptación de una arquitectura híbrida ConvMambaGRU, su comparación frente a una línea base GRU bajo un protocolo reproducible y el análisis separado de las variantes fonética y textual.

A partir de esta visión general, los apartados siguientes describen el entorno experimental, la preparación de los datos, el modelo de decodificación neuronal, la etapa de decodificación lingüística y el módulo complementario de síntesis de voz.

3.2 Entorno de desarrollo y reproducibilidad

La implementación se desarrolló en Python y PyTorch, sobre un entorno Ubuntu en WSL con aceleración CUDA, y se estructuró como un pipeline modular que separa carga de datos, preprocesado, definición del modelo, entrenamiento, inferencia y evaluación. La Tabla 4 resume la configuración utilizada.

Tabla 4. Configuración del entorno de desarrollo y ejecución experimental.

Componente	Configuración
Lenguaje principal	Python
Framework de Deep Learning	PyTorch
Gestión de entornos	Conda
Sistema de ejecución	Ubuntu sobre WSL
GPU	Nvidia RTX 3060
Memoria VRAM	12 GB
Aceleración	CUDA

Para facilitar la comparación entre variantes, se reutilizó una infraestructura común y se modificaron únicamente los componentes específicos de cada experimento. Además, se fijaron semillas aleatorias en los procesos principales y se conservaron configuraciones, checkpoints, métricas y salidas de evaluación. El código fuente, los notebooks de análisis y la organización general de los experimentos se recogen en el [repositorio del TFM](#), mientras que la línea base y parte del pipeline fonémico se apoyan en el repositorio original utilizado como referencia, ambos indicados en los anexos B y C correspondientemente.

3.3 Datos, análisis exploratorio y preprocesado

El sistema desarrollado se basa en el conjunto de datos del Brain-to-Text'25 Challenge, formado por registros neuronales intracorticales asociados a intentos de producción de habla. Estos datos proceden de un participante con ELA, hablante de inglés americano, implantado con matrices de microelectrodos en regiones corticales relacionadas con la producción del habla. Cada ensayo se organiza como un par entrada-salida: la entrada corresponde a una secuencia temporal multicanal de actividad neuronal y la salida a la frase objetivo, representada como una secuencia de fonemas o de caracteres según la variante de decodificación evaluada. Para más información sobre el montaje experimental utilizado en la recogida de estos datos, se recomienda consultar el trabajo de Card y otros [2].

Los datos utilizados en este trabajo se proporcionan siguiendo la representación empleada por el repositorio base del Brain-to-Text'25 Challenge. En esta representación, cada ensayo se codifica como una matriz de tamaño variable $[T, 512]$, donde T depende de la duración del ensayo y las 512 características corresponden a dos medidas extraídas por cada uno de los 256 electrodos registrados. Estas dos medidas recogen información complementaria de la actividad neuronal, la actividad de cruces de umbral y la potencia en banda de alta frecuencia o "spike-band power", calculadas por electrodo en ventanas temporales sucesivas. Cada instante temporal queda representado por un vector multicanal que resume la actividad neuronal registrada durante ese intervalo.

El conjunto de datos se divide en tres particiones: entrenamiento, validación y test, tal como se resume en la Tabla 5. En este trabajo se utilizaron las particiones de entrenamiento y validación. La partición de test no se empleó para el cálculo de métricas, ya que los organizadores del reto no han liberado públicamente sus transcripciones de referencia. Por ello, todas las comparaciones entre modelos se realizaron sobre el conjunto de validación.

Tabla 5. Distribución de ensayos por partición del conjunto de datos.

Partición	Nº de ensayos	Uso
Entrenamiento	8.072	Entrenamiento de los modelos
Validación	1.426	Evaluación y comparación de configuraciones
Test	1.450	No utilizado al no disponer de transcripciones públicas

Esta estructura condiciona tanto el preprocesado como el diseño de los modelos, ya que requiere trabajar con secuencias temporales de longitud variable y salidas lingüísticas también variables. El montaje experimental original y el flujo general de adquisición y decodificación de estos datos se describen en Card y otros [2], y se ilustran en la Figura 8.

Antes de describir los modelos, se presenta un resumen del análisis exploratorio realizado sobre el conjunto de datos y las transformaciones aplicadas para adaptarlo al entrenamiento de modelos secuencia-a-secuencia.

3.3.1 Consideraciones derivadas del análisis de datos

Antes de definir el pipeline final, se realizó un análisis exploratorio del conjunto de datos con el objetivo de identificar propiedades que pudieran condicionar el diseño del sistema. Este análisis incluyó la distribución de ensayos por sesión, la variabilidad de las longitudes temporales de entrada, la longitud de las secuencias objetivo y la relación entre la duración de la señal neuronal y la longitud lingüística de la frase.

En primer lugar, los ensayos presentan una longitud temporal variable, por lo que es necesario conservar la longitud real de cada ejemplo y aplicar mecanismos de relleno al formar lotes de entrenamiento. En segundo lugar, las salidas lingüísticas, tanto fonémicas como textuales, tampoco tienen una longitud uniforme. Por último, la relación entre la duración de la señal neuronal y la longitud de la frase no es fija, de modo que el problema debe formularse como una tarea secuencia-a-secuencia sin alineamiento explícito entre cada instante de entrada y cada unidad de salida.

Estas propiedades justifican las principales decisiones de preprocesado descritas en el siguiente apartado, control explícito de longitudes, adaptación de secuencias a lotes de entrenamiento y uso de una función de pérdida adecuada para secuencias no alineadas.

El análisis exploratorio completo, junto con las figuras descriptivas de distribución de ensayos, longitudes de secuencia, relación entrada-salida y variabilidad intersesión, se recoge en el Anexo A.

3.3.2 Representaciones objetivo

Una decisión importante del sistema es la definición de la representación lingüística objetivo, ya que condiciona el vocabulario de salida, la longitud de las secuencias a predecir y la estrategia de decodificación durante la inferencia.

En la variante fonética, el modelo aprende a predecir secuencias de unidades fonémicas expresadas en el alfabeto ARPAbet que posteriormente se transforman en texto mediante un modelo de lenguaje externo. Este enfoque sigue la lógica de los sistemas de decodificación en dos etapas descritos en la literatura reciente, en los que la señal neuronal se traduce primero a una representación subléxica y después a la secuencia textual más probable [1,2,18].

En la variante textual, la representación objetivo está formada directamente por una secuencia de caracteres. En este caso, el modelo aprende el mapeo entre la actividad neuronal y el texto final, eliminando la representación fonética intermedia.

Para mostrar la diferencia entre las dos representaciones, una misma palabra como "hello" se codifica de forma distinta según la variante. En la variante fonética, la salida esperada es una secuencia aproximada de sonidos, por ejemplo /HH AH L OW/. En la variante textual, la

salida esperada es una secuencia de caracteres "h e l l o". Esta diferencia es más relevante en inglés, donde la relación entre grafemas y sonidos no siempre es directa.

Las dos variantes comparten la misma señal de entrada y gran parte del pipeline de preparación de datos, pero difieren en el vocabulario de salida, la longitud de las secuencias objetivo y la estrategia de decodificación posterior. Esta comparación permite analizar el efecto de la propia representación objetivo sobre el rendimiento final del sistema.

3.3.3 Preprocesado de la señal neuronal

Antes del entrenamiento, se aplica una fase de preprocesado orientada a mejorar la estabilidad del aprendizaje y la calidad efectiva de la señal de entrada. Este bloque incluye transformaciones deterministas, aplicadas de forma consistente a los datos, y transformaciones de augmentación utilizadas únicamente durante el entrenamiento.

Una de las operaciones principales es el suavizado temporal mediante filtro gaussiano, aplicado tanto en entrenamiento como en validación para atenuar fluctuaciones rápidas no informativas sin alterar la dinámica global de la señal, ya que estas señales pueden contener ruido y presentar variaciones a lo largo del tiempo. Además, los registros neuronales pueden sufrir "drift" entre sesiones o incluso dentro de una misma sesión, lo que provoca cambios en su distribución estadística y dificulta la generalización del modelo. Por este motivo, también se aplica una normalización por día o sesión de registro con el objetivo de reducir diferencias intersesión y mitigar posibles cambios de distribución a lo largo del tiempo.

Durante el entrenamiento se incorporan también transformaciones de aumento sobre la señal de entrada para mejorar la robustez del modelo frente a pequeñas variaciones de amplitud y perturbaciones temporales. Entre ellas se incluyen ganancia aleatoria por canal, adición de ruido blanco, offsets constantes, ruido acumulativo de tipo random walk y recortes aleatorios al inicio de la secuencia. Estas perturbaciones no se aplican durante validación y actúan como un mecanismo de regularización. La Figura 10 muestra un ejemplo del efecto del suavizado gaussiano sobre dos señales de entrada.




Figura 10. Efecto del suavizado gaussiano sobre una señal neuronal. Fuente: elaboración propia.

3.4 Modelo de decodificación neuronal

El núcleo del sistema es el modelo de decodificación neuronal, encargado de transformar las secuencias temporales de actividad intracortical en una secuencia simbólica interpretable. En este trabajo se evalúan dos variantes de salida: una variante fonética, en la que el modelo predice la secuencia de fonemas que corresponde al mensaje que quiere transmitir la persona, y una variante textual, en la que la salida se corresponde directamente a una secuencia de caracteres. Ambas comparten la misma señal de entrada, el mismo esquema general de entrenamiento y gran parte del pipeline de inferencia, pero se diferencian en la representación objetivo y en el papel que desempeña el modelo de lenguaje durante la decodificación final.

Esta formulación permite comparar, bajo un marco común, el efecto de dos decisiones de diseño, la arquitectura del decodificador neuronal y la representación lingüística utilizada como salida. Se parte de una línea base basada en un modelo de red recurrente tipo GRU (Gated Recurrent Unit), alineada con los enfoques empleados en benchmarks recientes de decodificación "brain-to-text", y se explora una arquitectura híbrida ConvMambaGRU como aportación experimental propia. En ambos casos, la misma arquitectura puede adaptarse a la variante fonética o textual modificando únicamente el vocabulario de salida y la capa final de proyección.

3.4.1 Formulación común del problema

Cada ensayo se representa como una secuencia temporal de características neuronales de longitud variable. La entrada del modelo tiene forma general $[T, 512]$ donde T depende de la duración del ensayo y las 512 características corresponden a la representación multicanal de la actividad registrada. A partir de esta entrada, el modelo genera una secuencia temporal de logits sobre un vocabulario de salida, que puede estar formado por fonemas o por caracteres según la variante evaluada.

Ya que los ensayos presentan longitudes temporales distintas, las secuencias de entrada se agrupan en lotes mediante zero-padding hasta la longitud máxima del lote. No obstante, las longitudes reales de cada ejemplo se conservan durante el entrenamiento para evitar que el relleno influya en el cálculo de la pérdida. El entrenamiento se realiza mediante Connectionist Temporal Classification (CTC), una función de pérdida propuesta por Graves para entrenar modelos secuenciales cuando no se dispone de alineamiento explícito entre la entrada y la secuencia objetivo [21]. De forma general, la probabilidad de una secuencia objetivo y dada una secuencia de entrada x se define como la suma de las probabilidades de todos los alineamientos posibles π que colapsan en y :

$$P(y \mid x) = \sum_{\pi \in B^{-1}(y)} P(\pi \mid x)$$

donde B representa la operación de colapso que elimina repeticiones y símbolos en blanco. A partir de esta probabilidad, la pérdida CTC se define como:

$$L_{CTC} = -\log P(y \mid x)$$

Durante la inferencia, la salida temporal del modelo debe transformarse en una secuencia simbólica final. Para ello, se aplica el colapso propio de CTC, eliminando símbolos en blanco y repeticiones consecutivas. En la variante fonética, esta secuencia representa una hipótesis de fonemas que posteriormente debe convertirse en texto. En la variante textual, la secuencia colapsada ya corresponde directamente a una hipótesis de caracteres. La evaluación se realiza con métricas adaptadas a cada representación, PER para la salida fonémica y CER y WER para la salida textual o la transcripción final.

3.4.2 Arquitecturas evaluadas

Sobre la formulación común descrita anteriormente se evaluaron dos familias arquitectónicas. Una línea base recurrente basada en GRU y una variante híbrida ConvMambaGRU. Ambas reciben la misma representación de entrada y se entrenan mediante CTC, por lo que las diferencias de rendimiento pueden analizarse principalmente en función de la arquitectura del decodificador y de la representación objetivo utilizada en la salida.

La primera arquitectura corresponde a una línea base GRU, utilizada como referencia reproducible y alineada con los enfoques recurrentes habituales en sistemas recientes de decodificación "brain-to-text". El modelo parte de una capa específica por día o sesión de registro, orientada a reducir parcialmente la variabilidad intersesión. A continuación, la señal se agrupa mediante parches temporales, lo que reduce la longitud efectiva de la secuencia e incrementa el contexto local disponible en cada paso. El núcleo del modelo está formado por una pila de capas GRU unidireccionales, cuya salida se proyecta finalmente sobre el vocabulario correspondiente: fonemas en la variante fonética o caracteres en la variante textual.

La segunda familia arquitectónica explorada se basa en Mamba, una arquitectura de modelado secuencial basada en modelos de espacio de estados selectivos o "Selective State Space Models" (SSM) [22]. A diferencia de los Transformers, que modelan dependencias temporales con mecanismos de atención con coste cuadrático respecto a la longitud de la secuencia, Mamba plantea una formulación recurrente eficiente con escalado lineal, lo que la convierte en una alternativa atractiva para señales temporales largas.

De forma general, un modelo de espacio de estados continuo describe la evolución de un estado latente $h(t)$ a partir de una entrada $x(t)$ y genera una salida $y(t)$ mediante las ecuaciones:

$$\begin{aligned} h'(t) &= Ah(t) + Bx(t) \\ y(t) &= Ch(t) \end{aligned}$$

Donde A modela la dinámica interna del sistema, B determina como la entrada modifica el estado latente y C proyecta dicho estado hacia la salida. Tras discretizar la dinámica temporal, esta formulación puede expresarse como una recurrencia:

$$\begin{aligned}h_t &= \bar{A}_t h_{t-1} + \bar{B}_t x_t \\y_t &= C_t h_t\end{aligned}$$

La aportación principal de Mamba consiste en hacer que algunos parámetros del modelo dependan de la entrada en cada instante, permitiendo seleccionar qué información se conserva, se actualiza o se descarta a lo largo de la secuencia [22]. Esta capacidad de selección es beneficiosa para señales temporales ruidosas, como las neuronales, donde no todos los intervalos contienen la misma cantidad de información relevante.

La motivación para explorar este tipo de arquitectura proviene de trabajos recientes en reconocimiento automático del habla, donde modelos basados en Mamba y variantes convolucionales como ConMamba han mostrado un buen comportamiento en escenarios con datos limitados y secuencias largas. Zevallos y otros comparan ConMamba con Conformer en escenarios "low-resource" de ASR, mostrando un rendimiento comparable en contextos cortos, una mejora clara en entradas largas y una reducción del coste computacional en entrenamiento e inferencia [23].

A partir de esta motivación, en este trabajo se desarrolla ConvMambaGRU como variante experimental para explorar un modelado temporal más expresivo de la señal neuronal. Esta arquitectura mantiene la adaptación específica por sesión y el mecanismo de parcheado temporal, pero incorpora previamente un "front-end" convolucional compuesto por capas Conv1D residuales. Su objetivo es extraer patrones locales de corta duración antes del modelado secuencial, siguiendo la intuición de arquitecturas híbridas que combinan convoluciones para contexto local y bloques Mamba para dependencias de mayor alcance. Posteriormente, la representación se procesa mediante bloques Mamba residuales y, finalmente, se añade una GRU unidireccional como etapa de refinamiento temporal antes de la proyección al vocabulario de salida.

La Figura 11 muestra la estructura general de las arquitecturas implementadas. En ella se observa la secuencia de procesamiento común: adaptación por sesión, extracción local mediante convoluciones temporales, agrupación en parches, modelado secuencial y proyección al vocabulario de salida.




Figura 11. Arquitectura general de las variantes implementadas. Fuente: elaboración propia.

La principal diferencia entre las versiones fonética y textuales de cada arquitectura no reside en el procesamiento neuronal, sino en la capa final y en el vocabulario de salida. En las variantes fonética, la proyección final genera logits sobre el conjunto de unidades fonémicas; en las variantes textuales, la proyección se realiza sobre el vocabulario de caracteres. La Tabla 6 resume las configuraciones evaluadas.

Tabla 6. Resumen de arquitecturas implementadas.

Configuración	Arquitectura	Nº parámetros	Unidad objetivo	Clases de salida	Núcleo temporal	Decodificación posterior
GRU fonético	Línea base recurrente	44.315.177	Fonemas	41 clases	5 capas GRU	Conversión fonema-texto y rescoring
ConvMambaGRU fonético	Convolución + Mamba + GRU	50.653.728	Fonemas	41 clases	5 bloques Mamba + 1 GRU	Conversión fonema-texto y rescoring
GRU textual	Línea base recurrente	44.308.256	Caracteres	32 clases	5 capas GRU	Decodificación textual y rescoring
ConvMambaGRU textual	Convolución + Mamba + GRU	54.197.280	Caracteres	32 clases	5 bloques Mamba + 1 GRU	Decodificación textual y rescoring

Además de la línea base GRU y la arquitectura híbrida final ConvMambaGRU, durante la fase exploratoria se evaluó una variante basada únicamente en bloques Mamba, utilizada como comparación intermedia para analizar el efecto de estos bloques sin el componente convolucional y recurrente final.

Esta organización permite comparar tanto el efecto de la arquitectura como el de la representación objetivo bajo un mismo marco experimental. Además, evita duplicar la descripción de los modelos, ya que las variantes fonéticas y textuales comparten la mayor parte del procesamiento y solo difieren en la salida y en la etapa de decodificación lingüística posterior.

3.4.3 Variante fonética

La variante fonética plantea la salida del decodificador neuronal como una secuencia de fonemas. En lugar de predecir directamente la frase escrita, el modelo transforma primero la actividad neuronal en una representación subléxica relacionada con la estructura sonora del habla. Posteriormente, esta secuencia se convierte en texto mediante una etapa de decodificación lingüística y rescoring.

Este enfoque sigue la lógica de los sistemas de decodificación "brain-to-text" en dos etapas, en los que la predicción de fonemas permite separar parcialmente el modelado de la señal neuronal de la reconstrucción textual final [1,2,18]. Además, los fonemas constituyen una representación más próxima a la dinámica articulatoria del habla que la ortografía final, por lo que resultan más adecuados para modelar señales neuronales asociadas a habla imaginada.

La calidad del decodificador neuronal se evalúa inicialmente mediante Phoneme Error Rate (PER), calculado a partir de la distancia de edición entre la secuencia fonémica predicha y la secuencia de referencia. Esta métrica permite analizar el rendimiento del modelo antes de incorporar el efecto del modelo de lenguaje. La conversión de las hipótesis fonémicas a texto final, así como el uso de beam search y rescoring lingüístico, se describen de forma conjunta en el apartado 3.5.

3.4.4 Variante textual

La variante textual plantea una estrategia de decodificación directa, en la que el modelo aprende a transformar la actividad neuronal en una secuencia de caracteres sin utilizar una representación fonémica intermedia. En este caso, la salida del decodificador está más próxima al objetivo final del sistema, ya que la secuencia colapsada mediante CTC puede interpretarse directamente como una hipótesis textual.

La principal motivación de esta variante es simplificar el pipeline de decodificación. A diferencia del enfoque fonémico, no requiere una conversión posterior de fonemas a palabras ni depende de un vocabulario fonémico o de un lexicón de pronunciación. Esto

permite evaluar el rendimiento del sistema directamente sobre la transcripción final mediante métricas como Character Error Rate (CER) y Word Error Rate (WER).

A pesar de esto, esta formulación también introduce una dificultad adicional. Mientras que los fonemas mantienen una relación más cercana con la estructura sonora y articuladora del habla, los caracteres representan una codificación ortográfica que no tiene por qué estar directamente alineada con la dinámica neuronal de la producción del habla. Por eso, la variante textual se plantea como una alternativa experimental para analizar hasta qué punto una salida directa a caracteres puede competir con el enfoque fonémico en dos etapas.

3.5 Decodificación lingüística y rescoring

Una vez obtenida la salida temporal del decodificador neuronal, es necesario transformarla en una secuencia simbólica final. En ambas representaciones, fonética y textual, el modelo produce para cada paso temporal una distribución de puntuaciones sobre el vocabulario de salida. De forma más precisa, la salida del modelo puede representarse como una matriz de logits de tamaño $T \times P$, donde T es el número de pasos temporales de la secuencia de salida y P el tamaño del vocabulario, formado por fonemas o caracteres más el símbolo en blanco de CTC. La Figura 12 ilustra de forma esquemática esta salida temporal y su conversión posterior en una hipótesis textual.




Figura 12. Representación esquemática de la salida temporal del decodificador neuronal como matriz de logits.

La primera estrategia empleada fue la decodificación greedy. En este caso, se selecciona en cada paso temporal el símbolo con mayor probabilidad y posteriormente se eliminan las repeticiones consecutivas y los símbolos en blanco. Esta aproximación tiene un coste computacional reducido y permite obtener una primera estimación del rendimiento del decodificador neuronal. En la variante fonética, el resultado es una secuencia de fonemas que puede evaluarse mediante PER, mientras que, en la variante textual, el resultado es directamente una cadena de caracteres que puede evaluarse mediante CER y WER.

Para generar hipótesis más robustas se incorporó también beam search. A diferencia de la decodificación greedy, esta estrategia mantiene varias hipótesis candidatas durante el proceso de inferencia, en lugar de conservar únicamente la secuencia localmente más probable. De este modo, el sistema puede explorar alternativas que no necesariamente son óptimas en cada paso individual, pero que pueden resultar más plausibles al considerar la secuencia completa.

Sobre las hipótesis generadas mediante beam search se aplicó una etapa de rescoring con modelos de lenguaje. De forma general, la puntuación final de cada hipótesis combina la probabilidad asignada por el decodificador neuronal con la plausibilidad lingüística estimada por el modelo de lenguaje:

$$Score_{final}(y) = Score_{CTC}(y) + \alpha Score_{LM}(y)$$

donde α controla el peso relativo del componente lingüístico frente al componente neuronal. Este parámetro permite ajustar el grado de influencia del modelo de lenguaje durante la selección de la hipótesis final. La Figura 13 resume el proceso común de decodificación y rescoring para las variantes fonética y textual.




Figura 13. Proceso de decodificación y rescoring para las variantes fonética y textual. Fuente: elaboración propia.

El papel del rescoring varía según la representación objetivo. En la variante fonética, el modelo de lenguaje participa en la conversión de hipótesis fonémicas a texto, por lo que es una parte esencial del enfoque en dos etapas. En la variante textual, la salida del decodificador ya está expresada en caracteres, pero el rescoring puede ayudar a corregir errores ortográficos, secuencias poco probables o alternativas textuales con mayor coherencia lingüística.

En este trabajo se exploraron distintas configuraciones de decodificación, incluyendo "greedy decoding", "beam search" y "beam search" con rescoring lingüístico. En la variante textual se evaluaron modelos generalistas basados en Transformers, como variantes de GPT-2 accesibles a través de Hugging Face, y un modelo KenLM entrenado sobre el corpus textual disponible. KenLM es una librería eficiente para la consulta de modelos de lenguaje n-gram, utilizada en tareas de procesamiento del lenguaje y reconocimiento automático del

habla [24]. La comparación cuantitativa entre estas estrategias se presenta en el capítulo de resultados, donde se analiza su efecto sobre PER, CER y WER según la variante considerada.

3.6 Síntesis de voz

Como fase final del pipeline experimental, se incorporó un módulo de síntesis de voz o "text-to-speech" (TTS), cuya función es transformar las frases decodificadas en una señal de audio reproducible. Este bloque no realiza decodificación neuronal adicional, sino que actúa como una etapa posterior de salida orientada a completar el flujo actividad neuronal-texto-VOZ.

La motivación de su inclusión es que, en un contexto de restauración de la comunicación, la voz sintetizada ofrece una forma de interacción más inmediata y cercana al habla natural [1,20]. No obstante, esta etapa no pretende competir con las neuroprótesis de voz más avanzadas descritas en la literatura, sino actuar como una extensión funcional del sistema implementado. En este trabajo, el pipeline sigue siendo principalmente un sistema de decodificación neuronal a texto, al que se añade una fase posterior de conversión de texto a audio.

Para implementar esta etapa se utilizó la librería Coqui TTS [25], un framework abierto de síntesis de voz con modelos preentrenados capaz de generar audio a partir de texto sin necesidad de entrenar desde cero un modelo acústico y un vocoder. Con el fin de evitar incompatibilidades entre dependencias, este módulo se mantuvo en un entorno independiente del utilizado para el entrenamiento y evaluación de los decodificadores neuronales.

La Figura 14 resume este flujo de generación de audio, desde la salida textual del sistema de decodificación hasta la obtención del archivo de voz sintetizada.



Figura 14. Integración del módulo TTS como extensión del sistema. Fuente: elaboración propia.

La síntesis de voz se aplicó sobre las predicciones textuales generadas por el mejor modelo final, lo que permite observar cómo los aciertos y errores de decodificación se trasladan a la salida hablada. Es importante señalar que la voz generada por este módulo no corresponde a una reconstrucción directa de la voz del participante ni a una señal vocal decodificada desde la actividad neuronal, sino a una voz sintética generada a partir del texto mediante un modelo TTS preentrenado de propósito general. Aun así, esta etapa permite demostrar el funcionamiento extremo a extremo del sistema y deja abierta la posibilidad de integrar en el futuro modelos de voz personalizada.

4. Evaluación experimental y resultados

4.1 Protocolo experimental y métricas

Una vez implementadas las distintas arquitecturas y definidos los procedimientos de decodificación, se estableció un protocolo común de evaluación para comparar de forma controlada las variantes fonética y textual. En todos los casos, la evaluación se realizó sobre el conjunto de validación, formado por 1.426 ensayos o frases, manteniendo las mismas particiones de datos y el mismo esquema general de preprocesado descritos en el capítulo anterior. De este modo, las diferencias observadas entre configuraciones pueden atribuirse principalmente a la arquitectura empleada, a la representación objetivo y a la estrategia de decodificación lingüística.

La evaluación se planteó en dos niveles complementarios. En primer lugar, se analizó el rendimiento del decodificador neuronal sobre la representación objetivo generada por cada modelo. En segundo lugar, se evaluó el comportamiento del sistema completo una vez aplicada la etapa de decodificación lingüística y, cuando correspondía, el rescoring con modelo de lenguaje. Esta distinción es importante, ya que el comportamiento del decodificador neuronal y el del pipeline completo no siempre coinciden de forma directa [1].

En la variante fonética, la métrica principal utilizada para evaluar el decodificador neuronal fue la tasa de error fonético o PER (%), del inglés *Phoneme Error Rate*. Esta métrica cuantifica el número de inserciones, borrados y sustituciones necesarias para transformar la secuencia de fonemas predicha en la secuencia objetivo, normalizado por la longitud de la referencia. Además, para los modelos más representativos de esta variante, también se evaluó la tasa de error de palabra o WER (%), del inglés *Word Error Rate*, tras completar el pipeline fonema-texto, con el fin de valorar el comportamiento final del sistema.

En la variante textual, la salida del modelo ya está expresada directamente como secuencia de caracteres, por lo que la evaluación se realizó mediante la tasa de error por carácter o CER (%) del inglés *Character Error Rate* y WER (%). El CER permite analizar con mayor detalle el comportamiento del decodificador carácter a carácter, mientras que el WER ofrece una medida más próxima a la utilidad comunicativa final del sistema. En este contexto, el uso de modelos de lenguaje permite reordenar o corregir hipótesis candidatas generadas por el decodificador neuronal, ayudando a reducir errores de decodificación tanto en la salida textual directa como en la conversión fonema-texto de la variante fonética.

En todos los experimentos, las métricas se calcularon siguiendo el criterio estándar de distancia de edición, es decir, mediante el número mínimo de inserciones, borrados y sustituciones necesarias para transformar la secuencia predicha en la secuencia de referencia. Este criterio se aplicó de forma homogénea a PER, CER y WER [1,18].

Aunque en el contexto general de las neuroprótesis del habla también es relevante considerar la velocidad de comunicación, expresada normalmente en palabras por minuto, en este trabajo el análisis experimental se centró principalmente en las métricas de error sobre el conjunto de validación, ya que el objetivo principal es comparar arquitecturas y estrategias de decodificación bajo un mismo marco reproducible [1,2,5,14].

A partir de este protocolo, los resultados se presentan por separado para cada variante. En primer lugar, se analiza la variante fonética, a continuación, la variante textual, y finalmente, ambos enfoques se comparan de forma conjunta para identificar sus ventajas y limitaciones relativas.

4.2 Resultados de la variante fonética

Una vez implementados los modelos de la variante fonética y el bloque de decodificación y rescoring con modelo de lenguaje, se procedió a su evaluación sobre el conjunto de validación. En esta variante se analizaron dos niveles de rendimiento complementarios. En primer lugar, se evaluó la calidad del decodificador neuronal mediante el Phoneme Error Rate (PER). En segundo lugar, para los modelos más representativos, se analizó también la salida textual final mediante el Word Error Rate (WER) una vez aplicada la etapa de decodificación lingüística.

4.2.1 Tasas de error en fonemas

La Tabla 7 resume los resultados en PER obtenidos por los distintos modelos explorados en esta variante: la línea base GRU, la variante basada únicamente en Mamba y la arquitectura híbrida final ConvMambaGRU.

Tabla 7. Resumen de resultados PER en la rama fonética

Modelo	PER
GRU Baseline fonético	12,62 %
Mamba base fonético	15,37 %
ConvMambaGRU fonético	13,13 %

Como puede observarse, el mejor resultado en PER corresponde al sistema base que emplea un modelo recurrente GRU para realizar la decodificación fonética a partir de las señales neuronales, con un 12,62 %, seguida de la variante ConvMambaGRU, con un 13,13 %. Por su parte, la arquitectura basada únicamente en Mamba obtiene el peor rendimiento, con un 15,37 %. Estos resultados indican que, en términos de reconstrucción fonética directa, la arquitectura recurrente clásica sigue proporcionando la referencia más sólida dentro de esta variante. Al mismo tiempo, muestran que la variante híbrida logra aproximarse al comportamiento de la línea base y mejora con claridad a la versión Mamba pura.

Desde un punto de vista metodológico, esta comparación sugiere que la incorporación de bloques Mamba no produce por sí sola una mejora automática en la decodificación fonética. Este comportamiento es coherente con observaciones recientes en el ámbito "brain-to-text", donde las arquitecturas recurrentes siguen siendo difíciles de superar en tareas de decodificación secuencial con datos limitados. En concreto, trabajos recientes han señalado que el uso de Transformers y de otros modelos de espacio de estados profundos o SSM no han ofrecido todavía mejoras claras frente a líneas base recurrentes entrenadas en este tipo de datos [18,19].

4.2.2 Comparación en WER tras modelo de lenguaje

Aunque el PER es la métrica natural para evaluar la salida fonémica intermedia, el objetivo final del sistema es restaurar una comunicación textual completa. Por este motivo, para los modelos más competitivos también se analizó el WER tras completar la etapa de decodificación lingüística. En este nivel de evaluación se compararon la línea base GRU y la variante ConvMambaGRU. La Tabla 8 resume estos resultados.

Tabla 8. Resumen de resultados WER en la variante fonética.

Modelo	WER
GRU Baseline fonético	21,19 %
ConvMambaGRU fonético	24,11 %

En este caso, la línea base GRU vuelve a ofrecer el mejor resultado, con un WER del 21,19 %, frente al 24,11 % obtenido por la variante ConvMambaGRU. Aunque la diferencia en PER entre ambos modelos es inferior a un punto porcentual, la diferencia en WER se amplifica hasta casi tres puntos. Esto se debe a que PER y WER evalúan niveles distintos de la salida, el PER mide errores locales sobre unidades fonémicas, mientras que el WER contabiliza errores sobre palabras completas. Por tanto, una sustitución, inserción o borrado de pocos fonemas puede provocar que una palabra sea reconstruida de forma incorrecta o que el modelo de lenguaje seleccione una hipótesis textual distinta. Además, la etapa fonema-texto no depende únicamente del número total de errores fonémicos, sino también de su distribución dentro de la frase y de cómo afectan a palabras concretas. Por lo tanto, diferencias aparentemente pequeñas en PER pueden traducirse en diferencias mayores en WER tras la decodificación lingüística.

Estos resultados muestran además que el rendimiento final no depende únicamente de la calidad de la representación fonética, sino también de su interacción con la etapa lingüística posterior. Por esto, el análisis conjunto de PER y WER permite distinguir entre la capacidad del modelo para reconstruir fonemas a partir de la actividad cerebral y el rendimiento del sistema completo como herramienta de comunicación.

En conjunto, los resultados de la variante fonética muestran que la línea base GRU obtiene el mejor rendimiento tanto en PER como en WER. La arquitectura ConvMambaGRU, aunque no supera a la línea base, se sitúa como la mejor alternativa entre las variantes exploradas

basadas en Mamba. La interpretación de estas diferencias y su relación con la variante textual se aborda de forma conjunta en la discusión global del capítulo.

4.3 Resultados de la variante textual

Una vez implementados los dos modelos de la variante textual y definido el procedimiento de rescoring, se evaluó su rendimiento sobre el conjunto de validación mediante Character Error Rate (CER) y Word Error Rate (WER). En esta variante, el CER permite valorar la calidad de la secuencia de caracteres generada por el decodificador, mientras que el WER ofrece una medida más directamente relacionada con la utilidad comunicativa final del sistema.

La Tabla 9 resume los resultados obtenidos por las dos arquitecturas exploradas en esta variante, el modelo GRU textual y el modelo ConvMambaGRU textual. En ambos casos se muestran los resultados obtenidos mediante decodificación "greedy", y los resultados tras aplicar rescoring con modelo de lenguaje.

Tabla 9. Resumen de resultados de la rama textual con el mejor modelo de lenguaje.

Modelo	CER Greedy	CER Rescoring	WER Greedy	WER Rescoring
GRU textual + GPT2XL	15,45 %	13,41 %	33,14 %	26,26 %
ConvMambaGRU textual + GPT2XL	17,18 %	15,29 %	35,92 %	29,86 %

Como puede observarse, el mejor resultado corresponde a la arquitectura GRU textual tras aplicar rescoring con GPT-2 XL, alcanzando un CER del 13,41 % y un WER del 26,26 %. Sin rescoring, este mismo modelo obtiene un CER del 15,45 % y un WER del 33,14 %, lo que muestra una mejora importante al incorporar el modelo de lenguaje. En los experimentos realizados, la mejor configuración se obtuvo con un valor de $\alpha = 1,2$.

Por su parte, la variante ConvMambaGRU textual obtuvo un CER del 15,29 % y un WER del 29,86 % tras rescoring con GPT-2 XL. Aunque también mejora respecto a su decodificación greedy, con un CER del 17,18 % y un WER del 35,92 %, queda por debajo del modelo recurrente en ambas métricas finales.

Estos resultados indican que la decodificación directa a texto es viable con una arquitectura recurrente estándar, sin necesidad de recurrir necesariamente a una arquitectura más compleja. Además, refuerzan la idea de que una parte sustancial de la mejora final depende del entrenamiento del modelo y de su integración con la etapa posterior de modelo de lenguaje, más que únicamente de sustituir la arquitectura base por otra más sofisticada.

Efecto del modelo de lenguaje en el rescoring textual

Una vez evaluadas las dos arquitecturas de la variante textual, se analizó de forma específica el efecto del modelo de lenguaje utilizado en la etapa de rescoring sobre la variante ConvMambaGRU textual. Este análisis se realizó con el objetivo de estudiar hasta qué punto la elección del modelo de lenguaje podía modificar el rendimiento final de una misma arquitectura neuronal.

Debe tenerse en cuenta que los modelos GPT evaluados corresponden a modelos de lenguaje generalistas preentrenados, mientras que KenLM fue entrenado específicamente sobre el corpus textual disponible en el conjunto de datos. Por tanto, la comparación no solo refleja diferencias entre arquitecturas de modelo de lenguaje, sino también entre un enfoque generalista y otro adaptado al dominio.

La Tabla 10 resume las mejores métricas obtenidas para cada uno de los modelos de lenguaje evaluados, seleccionando en cada caso la configuración con menor WER.

Tabla 10. Mejores resultados de rescoring textual para la arquitectura ConvMambaGRU textual según el modelo de lenguaje utilizado.

Modelo de lenguaje	CER	WER	Valor α
GPT-2XL	15,29 %	29,86 %	2,0
KenLM 3-gram	16,13 %	30,94 %	7,5
KenLM 5-gram	16,13 %	30,95 %	7,5
GPT-2	15,85 %	31,10 %	0,8
GPT-Neo 125M	16,63 %	34,04 %	0,25
DistilGPT-2	16,64 %	34,07 %	0,25

Como puede observarse, dentro de este barrido sobre ConvMambaGRU textual, el mejor comportamiento global correspondió a GPT-2 XL, que obtuvo el menor WER entre los modelos evaluados. Entre los modelos más ligeros basados en n-gramas, el mejor resultado correspondió a KenLM 3-gram, aunque con un comportamiento prácticamente idéntico al de KenLM 5-gram. Por su parte, GPT-2 obtuvo un rendimiento intermedio, mientras que GPT-Neo 125M y DistilGPT-2 presentaron los peores resultados del conjunto probado.

Debe señalarse que este análisis detallado del efecto del modelo de lenguaje se realizó únicamente sobre la arquitectura ConvMambaGRU textual. En el caso del modelo GRU textual, no se llevó a cabo un barrido equivalente entre distintos modelos de lenguaje, sino que se utilizó directamente la mejor configuración final disponible.

Este análisis permite extraer dos conclusiones. En primer lugar, incluso en una formulación de decodificación directa a caracteres, la elección del modelo de lenguaje sigue teniendo un efecto apreciable sobre la calidad final del texto generado. En segundo lugar, el mejor rescoring obtenido para ConvMambaGRU textual no modifica la conclusión principal de la variante textual, ya que esta arquitectura continúa quedando por debajo del modelo GRU textual en la comparación global entre arquitecturas. Por lo tanto, la etapa de rescoring debe

entenderse como un componente relevante del rendimiento final, pero no suficiente por sí sola para compensar las diferencias entre decodificadores neuronales [18,19].

4.4 Comparación entre variantes fonética y textual

Una vez analizados por separado los resultados de las variantes fonética y textual, es necesario compararlas de forma conjunta para valorar qué formulación del problema ofrece el mejor equilibrio entre precisión, complejidad del pipeline e interpretación del sistema final. Aunque ambas persiguen el mismo objetivo, transformar actividad neuronal en una salida textual utilizable, lo hacen mediante estrategias conceptualmente distintas. La variante fonética plantea una decodificación en dos etapas, mientras que la variante textual aproxima directamente la señal neuronal al texto final.

La Tabla 11 resume los mejores resultados obtenidos en cada variante. Debe tenerse en cuenta que las métricas intermedias no son directamente equivalentes entre sí, ya que el PER se calcula sobre secuencias fonémicas y el CER sobre secuencias de caracteres. Por ello, la comparación final entre variantes se realiza principalmente a partir del WER.

Tabla 11. Comparación entre las mejores variantes de la rama fonética y textual.

Variante	Mejor modelo	Error intermedio	WER final
Fonética	GRU base fonético	12,62 % (PER)	21,19 %
Textual	GRU textual	13,41 % (CER)	26,26 %

A partir de estos resultados, puede observarse que la variante fonética obtiene el mejor rendimiento final en términos de WER, con un 21,19 %, frente al 26,26 % alcanzado por la mejor configuración de la variante textual. Este resultado sugiere que, en el marco experimental de este trabajo, la estrategia en dos etapas sigue ofreciendo una mayor ventaja cuando el objetivo es maximizar la precisión del sistema completo. La posibilidad de desacoplar la decodificación neuronal de la reconstrucción lingüística permite aprovechar de forma más explícita la estructura fonológica del habla y apoyarse posteriormente en el modelo de lenguaje para obtener una salida textual más coherente [1,18,19].

A pesar de esto, la comparación no debe interpretarse únicamente en términos de error final. La variante textual presenta una ventaja importante desde el punto de vista del diseño del sistema, ya que simplifica la representación objetivo y evita la necesidad de una etapa fonética intermedia. Esto reduce la dependencia de recursos lingüísticos específicos y acerca el problema directamente a la salida comunicativa deseada. Además, aunque en inglés la relación entre escritura y pronunciación es relativamente irregular, en idiomas con una correspondencia grafema-fonema más transparente, como el castellano, una variante textual directa podría resultar potencialmente más competitiva.

La comparación entre las dos variantes también permite extraer una conclusión sobre el papel del modelo de lenguaje. En la variante fonética, este componente cumple una función

de reconstrucción y corrección sobre una representación intermedia, mientras que en la variante textual, actúa como mecanismo de refinamiento sobre secuencias ya expresadas en caracteres. En los dos casos, los resultados muestran que el rendimiento final no depende solo del decodificador neuronal, sino también de cómo se articula con la etapa lingüística posterior [18,19].

La variante fonética aparece en este trabajo como la alternativa más precisa, mientras que la variante textual se presenta como la formulación más directa y sencilla del problema. La primera ofrece mejores resultados finales y una mayor robustez del pipeline completo, mientras que la segunda reduce la complejidad conceptual del sistema, aunque a costa de una pérdida de rendimiento en las métricas finales.

4.5 Análisis de errores

Además de comparar el rendimiento global mediante métricas agregadas, es relevante analizar con mayor detalle los errores cometidos por cada variante del sistema. Este análisis permite estudiar no solo cuánto se equivoca cada modelo, sino también en qué condiciones aparecen los errores, cómo evolucionan con la longitud de las secuencias, qué confusiones son más frecuentes y hasta qué punto el modelo de lenguaje consigue corregir o amplificar errores del decodificador neuronal. En los apartados siguientes se estudian por separado los patrones de error observados en la variante fonética y en la variante textual.

4.5.1 Análisis de errores en la variante fonética

Más allá de las métricas agregadas de PER y WER, es relevante analizar con mayor detalle la naturaleza de los errores cometidos en la variante fonética. Para este análisis se utilizó el modelo con mejor rendimiento dentro de esta variante, la línea base GRU fonética, ya que fue la configuración que obtuvo los mejores resultados tanto en reconstrucción de fonemas como en salida textual final. Este enfoque introduce dos niveles de posible error: la reconstrucción de la secuencia de fonemas a partir de la señal neuronal y la conversión de dicha representación intermedia en la frase textual final tras la etapa de modelo de lenguaje.

En primer lugar, se estudió la relación entre la longitud de la secuencia y el error cometido por el sistema. Los resultados muestran que tanto el PER como el WER tienden a aumentar a medida que crece la longitud de la frase objetivo y, en paralelo, la longitud de la secuencia fonémica de referencia. Este comportamiento es esperable, ya que las frases más largas ofrecen más oportunidades para la acumulación de errores locales. La Figura 15 muestra esta tendencia.




Figura 15. Evolución del PER y WER fonémicos en función de la longitud de la frase. Fuente: elaboración propia.

Además, se analizó la variabilidad del rendimiento entre sesiones de registro. Este análisis mostró que el error no se distribuye de forma uniforme entre sesiones, sino que existen diferencias intersesión tanto en PER como en WER final. Este resultado es coherente con la variabilidad observada en el análisis exploratorio de los datos y sugiere que parte del error puede estar asociado a cambios en la estabilidad del registro neural, a la distribución desigual de ensayos por sesión o a diferencias en la calidad de la señal entre días de adquisición. La Figura 16 resume esta evolución.




Figura 16. Evolución de PER y WER por sesión en la variante fonética. Fuente: elaboración propia.

En un nivel más específico, se estudió la distribución de errores a nivel fonético. Se analizó tanto la frecuencia de aparición de los distintos fonemas en las secuencias de referencia como las sustituciones más frecuentes entre fonemas reales y fonemas predichos. Este análisis permitió observar que el modelo no distribuye los errores de forma uniforme sobre todo el inventario fonético, sino que ciertas unidades presentan una tasa de sustitución superior a otras. La Tabla 12 resume los fonemas con mayor tasa relativa de sustitución,

normalizando el número de sustituciones por la frecuencia total de aparición de cada fonema en el conjunto de validación.

Tabla 12. Fonemas con mayor tasa de sustitución.

Fonema de referencia	Frecuencia en referencia	Número de sustituciones	Tasa de sustitución
G	364	84	23,08 %
CH	167	38	22,75 %
JH	187	42	22,46 %
UH	192	43	22,40 %
EH	868	193	22,24 %
OW	454	97	21,37 %
SH	176	36	20,45 %
EY	525	105	20,00 %
AA	661	113	17,10 %
AE	772	127	16,45 %
D	1274	199	15,62 %
ER	620	94	15,16 %
IY	1162	141	12,13 %

Como puede observarse, los mayores niveles de error relativo se concentran en fonemas como F, B, IY, TH y DH. Al mismo tiempo, algunos fonemas más frecuentes, como CH o IH, también acumulan un número elevado de sustituciones, aunque su tasa relativa es menor debido a su mayor presencia en el conjunto de validación. Esto sugiere que la dificultad de decodificación no depende únicamente de la frecuencia de aparición de cada unidad.

También se analizaron los pares de confusión fonémica más frecuentes. La Tabla 13 resume las sustituciones observadas con mayor frecuencia entre fonema de referencia y fonema predicho, mientras que la Figura 17 muestra una matriz de confusión reducida con estas relaciones más habituales.

Tabla 13. Pares de sustitución fonémica más frecuentes.

Fonema de referencia	Fonema predicho	Frecuencia
D	T	127
T	D	90
AH	IH	70
S	Z	70
Z	S	58
IH	AH	55
N	D	47
AH	ER	45
EH	IH	45




Figura 17. Matriz de confusión reducida para las sustituciones fonémicas más frecuentes. Fuente: elaboración propia.

Como puede observarse, varias de las confusiones más frecuentes son recíprocas, como ocurre en los pares CH-SH, R-Y o HH-AE, lo que sugiere una dificultad sistemática del modelo para discriminar ciertos fonemas próximos dentro del espacio de representación aprendido.

Para estudiar con mayor detalle si existía una relación entre la dificultad de decodificación y la frecuencia de aparición de cada fonema, se representó la tasa de sustitución frente al número de apariciones de cada unidad fonémica. Esta relación se muestra en la Figura 18.




Figura 18. Relación entre la frecuencia de aparición del fonema y su tasa de sustitución. Fuente: elaboración propia.

La figura sugiere que no existe una relación estrictamente lineal entre frecuencia y error. Aunque algunos fonemas poco frecuentes presentan tasas de sustitución elevadas, también aparecen fonemas relativamente frecuentes con errores apreciables. Por lo tanto, la frecuencia de aparición no explica por sí sola el patrón de errores observado. Esto apunta a que la confusión entre fonemas, probablemente asociada a su proximidad articulatoria o acústico-fonológica, también desempeña un papel importante.

Por otro lado, al analizar la salida textual final tras el modelo de lenguaje, se observa que una parte importante de los errores fonémicos no se traduce necesariamente en un error textual grave. Esto indica que la segunda etapa del sistema tiene cierta capacidad correctora y puede resolver secuencias fonémicas imperfectas siempre que estas conserven suficiente estructura lingüística. Sin embargo, también se observaron casos en los que una secuencia fonémica razonablemente cercana a la referencia daba lugar a una frase final incorrecta, lo que muestra que la relación entre error fonémico y error textual no es estrictamente lineal.

Desde un punto de vista cualitativo, se seleccionaron además ejemplos representativos de frases bien resueltas, frases con errores intermedios y frases con errores graves. La Tabla 14 recoge algunos de estos casos.

Tabla 14. Ejemplos cualitativos de errores en la variante fonética.

Tipo de caso	Texto de referencia	Secuencia de referencia	Secuencia decodificada	Texto predicho tras LM	PER	WER	CER LM
Bien resuelto	Of course.	AH, V, SIL, K, AO, R, S, SIL	AH, V, SIL, K, OY, S, SIL	of course	12 %	0 %	0 %
Bien resuelto	House robberies.	HH, AW, S, SIL, R, AA, B, ER, IY, Z, SIL	HH, AW, S, SIL, R, AH, M, ER, IY, Z, SIL	house robberies	18 %	0 %	0 %
Bien resuelto	Join the gang.	JH, OY, N, SIL, DH, AH, SIL, G, AE, NG, SIL	JH, OY, SIL, DH, AH, SIL, G, EY, NG, SIL	join the gang	18 %	0 %	0 %
Error intermedio	That is horrible.	DH, AE, T, SIL, IH, Z, SIL, HH, AO, R, AH, B, AH, L, SIL	DH, IH, T, SIL, IH, Z, SIL, OW, V, ER, G, ER, G, ER, SIL	that is overtake	14 %	30 %	37,5 %
Error intermedio	Employee controller.	EH, M, P, L, OY, IY, SIL, K, AH, N, T, R, OW, L, ER, SIL	IH, M, AO, OY, IH, IY, NG, SIL, K, AH, N, T, UH, UW, L, IY, SIL	employee control	16 %	50 %	15,8 %
Error grave	Not too long ago.	N, AA, T, SIL, T, UW, SIL, L, AO, NG, SIL, AH, G, OW, SIL	N, AE, T, SIL, T, UW, SIL, L, AY, K, AH, K, OW, SIL	matt to slugger	20 %	100 %	68,8 %
Error grave	I love eating pecan pie.	AY, SIL, L, AH, V, SIL, EH, T, IH, NG, SIL, P,	AY, SIL, L, AH, V, SIL, IY, T, IH, NG, SIL, P,	live ending performed by	34 %	100 %	65,2 %

		IH, K, AA, R, N, SIL, P, AY, SIL	AH, K, AA, N, SIL, P, AY, SIL				
Error grave	There's no deductions.	DH, EH, R, Z, SIL, N, OW, SIL, D, IH, D, AH, K, SH, AH, N, Z, SIL	DH, EH, R, Z, SIL, T, OW, SIL, T, IH, D, AH, K, SH, AH, Z, SIL	theirs tall tension	30 %	100 %	60 %

Estos ejemplos muestran que un PER bajo no garantiza necesariamente una reconstrucción textual correcta. En algunos casos, secuencias fonémicas relativamente próximas a la referencia conducen a errores léxicos o semánticos importantes en la salida final, mientras que en otros el modelo de lenguaje consigue corregir pequeñas desviaciones y recuperar la frase correcta.

El análisis de errores de la variante fonética permite extraer tres conclusiones principales. En primer lugar, el error tiende a aumentar con la longitud de la frase y de la secuencia fonética. En segundo lugar, las confusiones no se distribuyen de forma homogénea entre fonemas, sino que se concentran en determinadas unidades y en ciertos pares de sustitución recurrentes. En tercer lugar, la etapa de modelo de lenguaje actúa como un mecanismo corrector parcial, aunque no puede compensar completamente errores fonémicos acumulados o trayectorias demasiado alejadas de la referencia. Esto confirma que, en esta variante, el comportamiento del sistema debe interpretarse como el resultado conjunto de la decodificación neuronal fonética y del procesamiento lingüístico posterior.

4.5.2 Análisis de errores en la variante textual

Al igual que en la variante fonética, las métricas agregadas de CER y WER permiten resumir el rendimiento global de la variante textual, pero no bastan por sí solas para caracterizar con detalle la naturaleza de los errores cometidos por el sistema. En este caso, el análisis es especialmente relevante porque la salida del decodificador está expresada directamente en caracteres, de modo que los errores afectan de forma inmediata a la frase final. Además, esta variante permite estudiar con claridad el efecto del rescoring lingüístico, comparando la decodificación greedy con la salida obtenida tras beam search y modelo de lenguaje.

En primer lugar, se analizó la relación entre la longitud de la frase y el error medio a nivel de caracteres. La Figura 19 muestra la evolución del CER medio en función de la longitud de la frase, comparando la salida greedy con la salida final tras beam search y modelo de lenguaje. En términos generales, el error a nivel de caracteres aumenta a medida que crece la longitud de la secuencia. Al mismo tiempo, puede observarse que el rescoring reduce el error en todos los intervalos de longitud considerados, lo que confirma que el modelo de lenguaje introduce una mejora consistente también en frases largas.




Figura 19. CER medio en función de la longitud de la frase en la rama textual. Fuente: elaboración propia.

De forma complementaria, se estudió la evolución del WER medio según la longitud de la frase. La Figura 20 muestra que, también a nivel de palabra, las frases más largas presentan en general mayor dificultad que las más cortas. Aun así, el patrón global indica que la salida obtenida tras beam search y modelo de lenguaje mejora sistemáticamente frente a la decodificación greedy, lo que sugiere que el rescoring no solo corrige errores ortográficos locales, sino que también ayuda a seleccionar secuencias léxicas globalmente más plausibles.




Figura 20. WER medio en función de la longitud de la frase en la rama textual. Fuente: elaboración propia.

Además del efecto de la longitud, se analizó la variabilidad del rendimiento entre sesiones de registro. La Figura 21 representa la evolución del WER medio por sesión en orden cronológico, comparando la salida greedy y la salida final tras rescoring. El resultado muestra una variabilidad apreciable entre sesiones, con diferencias claras en el nivel de

error medio alcanzado. A pesar de esto, la mejora introducida por el rescoring se mantiene de forma bastante estable a lo largo de la mayoría de las sesiones.




Figura 21. Evolución del WER medio por sesión en orden cronológico en la rama textual. Fuente: elaboración propia.

Un aspecto relevante en esta variante fue el análisis de las confusiones léxicas más frecuentes. A diferencia de la variante fonética, donde el error se estudia sobre un vocabulario de fonemas, aquí es más natural observar qué palabras tienden a confundirse con mayor frecuencia tras la decodificación. La Figura 22 muestra una matriz de confusión reducida con algunas de las confusiones léxicas más frecuentes observadas en la salida beam search + LM. Este tipo de errores se concentra principalmente en palabras cortas y muy frecuentes, muchas de ellas con función estructural dentro de la frase.




Figura 22. Matriz de confusión reducida para las confusiones léxicas más frecuentes en la rama textual. Fuente: elaboración propia.

Este patrón indica que, incluso cuando el modelo de lenguaje corrige una parte importante de los errores de carácter, sigue habiendo ambigüedades en elementos léxicos cortos y

frecuentes. Esto ayuda a explicar por qué una mejora apreciable en CER no siempre se traduce de forma proporcional en una mejora equivalente en WER.

Desde un punto de vista global, el análisis muestra que el rescoring lingüístico mejora la salida textual de forma clara frente a la decodificación greedy, aunque esta mejora no se distribuye de manera homogénea sobre todas las muestras. Existen muchos casos en los que beam search por sí solo apenas modifica la salida inicial, mientras que la incorporación del modelo de lenguaje sí produce una corrección importante. También aparecen casos en los que la hipótesis final empeora ligeramente respecto a una salida inicialmente correcta o casi correcta, lo que confirma que el rescoring constituye un mecanismo de corrección potente, aunque no infalible.

Desde un punto de vista cualitativo, se seleccionaron ejemplos representativos de predicciones bien resueltas y de errores graves. La Tabla 15 muestra que, en los casos favorables, el modelo textual puede producir directamente frases correctas o casi correctas, o bien secuencias con pequeñas desviaciones locales que el modelo de lenguaje termina de corregir completamente. En cambio, en los casos más problemáticos, la salida generada por el decodificador permanece muy alejada de la referencia incluso tras el rescoring.

Tabla 15. Ejemplos cualitativos de errores en la rama textual.

Tipo de caso	Texto original	Salida greedy	Salida LM	WER greedy	WER LM
Bien resuelto	one thing or the other.	one think or the other	one thing or the other	20 %	0 %
Bien resuelto	i guess i like to take care of it.	i juss i like to take care of it	i guess i like to take care of it	11 %	0 %
Bien resuelto	then it's twice as hard.	then its twece as hord	then its twice as hard	40 %	0,00 %
Error grave	are you pleased with this decision?	leats thin thi eein	leats thin the eein	100 %	100 %
Error grave	an absolute certainty.	and ipturlut sertay	and iturlut setay	100 %	100 %
Error grave	not too long ago.	nad to lakago	mod to lakago	100 %	100 %

Estos ejemplos muestran que el modelo de lenguaje puede corregir errores ortográficos o léxicos moderados cuando la hipótesis inicial conserva suficiente cercanía con la frase objetivo, pero también que su capacidad de recuperación es limitada cuando la secuencia generada por el decodificador ya está excesivamente degradada.

Para estudiar de forma más específica el efecto positivo del rescoring, se recopilamos ejemplos en los que la incorporación del modelo de lenguaje produce una mejora sustancial respecto a la salida inicial. La Tabla 16 ilustra varios casos representativos en los que el rescoring corrige de forma clara la hipótesis textual, llegando incluso a reconstruir completamente la frase correcta a partir de una salida greedy con errores relevantes.

Tabla 16. Ejemplos de mejora sustancial debida al rescoring lingüístico en la rama textual.

Texto original	Salida greedy	Salida LM	WER greedy	WER LM
real rough type camping.	weall rogh tipe camping	real rough type camping	75 %	0 %
seventy awful years.	siventy owful years	seventy awful years	67 %	0 %
i'm trying to think.	ime trying to thin	im trying to think	40 %	0 %
it was written many years ago.	it was twenten miny yearsago	it was twenten many years ago	50 %	0 %

Estos ejemplos exponen que el modelo de lenguaje puede corregir eficazmente errores ortográficos, segmentaciones inestables y sustituciones léxicas locales cuando la hipótesis inicial conserva suficiente proximidad con la referencia.

No obstante, también se observaron casos en los que la salida final empeora respecto a la hipótesis inicial. La Tabla 17 recoge algunos ejemplos representativos de este comportamiento. En ellos, el modelo de lenguaje introduce modificaciones que no acercan la hipótesis a la referencia, sino que la desplazan hacia secuencias alternativas más plausibles desde un punto de vista estadístico, pero incorrectas en el contexto concreto.

Tabla 17. Ejemplos en los que el rescoring lingüístico empeora la salida final en la rama textual.

Texto original	Salida greedy	Salida LM	WER greedy	WER LM
did you see it the other night?	did you see it the olbo night	did you see it the abo right	14 %	29 %
i don't know what you think about that.	i dont know want the think apout that	i dont kno wat the think apout that	38 %	50 %
cars have come down in price significantly.	cours of come dot it prose sountitut	cours of com dot it prose sotilitut	86 %	100 %
the morning sun light is white.	the moning sun lot is whight	the moning sin lot is whit	50 %	67 %

Estos ejemplos confirman que el rescoring actúa como un corrector potente, pero no infalible. En determinadas situaciones, especialmente cuando la hipótesis original ya contiene errores severos o muy ambiguos, el modelo de lenguaje puede reforzar una secuencia alternativa errónea en lugar de aproximarla a la referencia.

El análisis de errores de la variante textual permite extraer varias conclusiones. En primer lugar, el error tiende a aumentar con la longitud de la frase, tanto a nivel de caracteres como a nivel de palabras. En segundo lugar, existe una variabilidad apreciable entre sesiones, aunque el rescoring mantiene su efecto corrector de forma bastante consistente. En tercer lugar, las confusiones más frecuentes no se limitan a palabras raras o largas, sino que afectan también a palabras muy frecuentes y de longitud reducida. Finalmente, la comparación entre salida greedy y salida final confirma que el modelo de lenguaje

desempeña un papel decisivo en la calidad final del texto generado, actuando como un corrector eficaz pero no completamente libre de errores o sesgos de reordenación.

En resumen, el análisis de errores de ambas variantes muestra que el rendimiento del sistema no depende únicamente de la capacidad del decodificador neuronal para reconstruir una representación intermedia o final, sino también del modo en que esa representación interactúa con la etapa lingüística posterior. En la variante fonética, esta interacción se manifiesta en la conversión de secuencias fonémicas imperfectas en frases textuales plausibles, mientras que en la variante textual el modelo de lenguaje actúa principalmente como mecanismo de corrección y priorización sobre hipótesis ya expresadas en caracteres. En los dos casos, los resultados confirman que la calidad final del sistema debe entenderse como el producto conjunto del decodificador neuronal y del procesamiento lingüístico posterior.

4.5.3 Ejemplos cualitativos de síntesis de voz

Además de la evaluación textual, se generaron ejemplos de audio mediante Coqui TTS a partir de las predicciones obtenidas por la variante fonética con mejor rendimiento. Esta evaluación no pretende medir de forma objetiva la calidad del sintetizador, sino mostrar cómo los aciertos y errores de decodificación se trasladan a la salida hablada final del sistema. Para ello, se seleccionaron dos ejemplos representativos, un caso correctamente decodificado, en el que la frase predicha coincide con la referencia, y un caso con error grave, en el que la hipótesis textual generada tras el modelo de lenguaje difiere de la frase objetivo. La Figuras 23 muestra, la forma de onda y el espectrograma de los audios sintetizados para ambos casos.




Figura 23. Forma de onda y espectrograma del audio sintetizado para un ejemplo correctamente decodificado por la variante fonética. Fuente: elaboración propia.

Para complementar esta inspección visual, la Tabla 18 recoge las frases de referencia, el texto finalmente utilizado como entrada del sintetizador y el enlace a la página web creada donde se pueden escuchar los archivos de audio generados. El código HTML así como la página desplegada pueden consultarse en el Anexo D.

Tabla 18. Ejemplos de audio sintetizado mediante Coqui TTS a partir de predicciones de la variante fonética.

Caso	Texto de referencia	Texto predicho	Enlace al audio
Correctamente decodificado	How does it keep the cost down	how does it keep the cost down	Enlace
Error grave	Wait a minute we know this thing isn't	wait a meta oui know this thing eason	Enlace

4.6 Discusión global de resultados

Los resultados obtenidos en este trabajo permiten extraer varias conclusiones relevantes sobre la decodificación de habla imaginada a partir de actividad neuronal, así como sobre el papel relativo de la arquitectura neuronal, la representación objetivo y la etapa de decodificación lingüística. El análisis realizado muestra que el rendimiento final del sistema no depende únicamente del decodificador neuronal, sino de la interacción entre la representación elegida, la robustez del modelo frente a la variabilidad temporal de la señal y la capacidad del modelo de lenguaje para corregir y priorizar hipótesis plausibles.

En primer lugar, la comparación entre la variante fonética y la variante textual confirma que ambas formulaciones son estrategias viables para abordar el problema "brain-to-text", pero presentan propiedades distintas. La variante fonética descompone el problema en dos etapas y ofrece una estructura más modular e interpretable, al permitir distinguir entre errores originados en la etapa neuronal y errores introducidos o corregidos en la etapa lingüística. La variante textual, por su parte, plantea una formulación más directa, al decodificar caracteres desde la propia señal neuronal. Sin embargo, los resultados muestran que esta simplificación del pipeline no elimina la necesidad de una etapa lingüística posterior, sino que desplaza su función hacia la corrección y priorización de secuencias ya expresadas en caracteres.

En segundo lugar, los resultados indican que una mayor complejidad arquitectónica no garantiza por sí sola una mejora clara. Tanto en la variante fonética como en la textual, las variantes híbridas basadas en bloques convolucionales y Mamba no superaron a la línea base recurrente. En la variante fonética, el modelo GRU base mantuvo el mejor resultado final en WER, aunque ConvMambaGRU resultó competitivo en PER. En la variante textual, el modelo GRU volvió a ofrecer el mejor comportamiento global frente a ConvMambaGRU textual. Esto sugiere que, al menos en este contexto experimental y con el volumen de datos disponible, las arquitecturas recurrentes clásicas continúan siendo referencias sólidas y difíciles de superar.

Este resultado no debe interpretarse como una refutación del interés de arquitecturas más modernas, sino como una señal de que la decodificación neuronal del habla presenta restricciones particulares. La cantidad de datos es limitada, la señal presenta variabilidad entre sesiones y las secuencias objetivo dependen simultáneamente de información local y contextual. En este escenario, una arquitectura más compleja puede requerir un ajuste mucho más preciso para traducirse en una mejora efectiva. Esta interpretación es coherente con observaciones del Brain-to-Text Benchmark '24, donde las mayores mejoras se asociaron más a estrategias de entrenamiento, ensembles y refinamiento con modelos de lenguaje que a un reemplazo exitoso de la línea base recurrente por arquitecturas más sofisticadas como Transformers o modelos de espacio de estados [19].

En tercer lugar, el trabajo confirma que la etapa de modelo de lenguaje tiene un impacto decisivo sobre el rendimiento final del sistema. En la variante fonética, esta influencia se aprecia en la distancia entre la calidad de la secuencia de fonemas intermedia y la calidad del texto final. Además, la comparación entre PER y WER muestra que pequeñas diferencias en la secuencia de fonemas pueden amplificarse en la salida textual final, ya que un número reducido de errores fonéticos puede alterar palabras completas o llevar al modelo de lenguaje a seleccionar una hipótesis distinta. En la variante textual, el análisis de errores mostró que el rescoring con beam search y modelo de lenguaje reduce de forma clara tanto el CER como el WER frente a la decodificación greedy. Al mismo tiempo, también se observaron casos en los que el rescoring introduce errores adicionales, lo que demuestra que su contribución es valiosa, pero no infalible.

Este papel del modelo de lenguaje tiene una implicación metodológica importante. La evaluación de un sistema de neuroprótesis del habla no debería limitarse a comparar arquitecturas neuronales en aislamiento, sino que debe entenderse como la evaluación de un pipeline completo. Un decodificador neuronal no es necesariamente mejor solo porque reduzca una métrica intermedia si esa mejora no se traduce después en una reducción del error final de palabras. De la misma forma, un modelo con una representación intermedia menos precisa puede seguir siendo competitivo si la etapa lingüística posterior consigue explotar adecuadamente la estructura residual de la hipótesis generada.

En cuarto lugar, el análisis de errores ha mostrado que la dificultad del problema aumenta con la longitud de las secuencias y que existe una variabilidad apreciable entre sesiones. En las dos variantes, las frases largas presentan mayores tasas de error, lo que resulta coherente con la acumulación progresiva de pequeñas desviaciones a lo largo de la secuencia temporal. Además, la evolución del error entre sesiones sugiere que el sistema sigue siendo sensible a cambios intersesión en la señal neuronal o en la distribución de muestras. Esto expone que uno de los retos principales para futuras mejoras no es únicamente aumentar la capacidad representacional del modelo, sino también mejorar su robustez y estabilidad temporal.

A partir de estos resultados, este trabajo aporta la conclusión práctica de que, dentro del marco experimental considerado, las arquitecturas recurrentes base constituyen una

solución competitiva, tanto por rendimiento como por simplicidad relativa de implementación. La variante fonética ofrece una formulación modular e interpretable, mientras que la variante textual demuestra que una decodificación directa también puede resultar efectiva siempre que disponga de una etapa posterior de rescoring bien ajustada.

En este sentido, una de las implicaciones más relevantes del trabajo es que sigue existiendo un amplio margen de mejora futura. La literatura reciente sugiere que parte de ese margen podría provenir no tanto de sustituir completamente la arquitectura base, sino de combinar mejores estrategias de entrenamiento, objetivos intermedios más informativos y etapas de rescoring más potentes.

Finalmente, la incorporación del módulo de síntesis de voz, aunque no modifica las métricas de decodificación, refuerza la orientación aplicada del trabajo. Esta extensión muestra cómo una salida textual decodificada desde actividad neuronal puede integrarse en una cadena funcional más cercana a una neuroprótesis de comunicación real.

En resumen, este trabajo confirma que la restauración de la comunicación mediante decodificación neuronal del habla depende de un equilibrio entre modelado neuronal y estructura lingüística. La principal aportación no está solamente en comparar arquitecturas, sino en mostrar que el rendimiento final viene dado por la interacción entre todos los componentes del pipeline.

5. Conclusiones y líneas de trabajo futuras

5.1 Conclusiones

Este Trabajo Fin de Máster ha abordado la decodificación de habla imaginada a partir de actividad neuronal intracortical como un problema secuencia-a-secuencia orientado a la restauración de la comunicación. A partir de este planteamiento, se ha diseñado e implementado un sistema reproducible de tipo "brain-to-text", capaz de transformar señales neuronales en texto y, de forma complementaria, en voz sintetizada.

La primera conclusión del trabajo es que el rendimiento de un sistema de decodificación neuronal del habla no puede entenderse únicamente como el resultado de una arquitectura neuronal aislada. La representación lingüística elegida, el tratamiento de la variabilidad temporal de la señal y la integración con modelos de lenguaje condicionan de forma decisiva la salida final. Por ello, la evaluación de este tipo de sistemas debe plantearse como la evaluación de un pipeline completo, desde la señal neuronal hasta la hipótesis textual final.

En segundo lugar, los resultados obtenidos muestran que la variante fonética en dos etapas continúa siendo, dentro del marco experimental considerado, la estrategia más eficaz en términos de error final de palabra. Su principal ventaja no reside solo en la precisión, sino también en su modularidad, que permite separar la decodificación neuronal de la reconstrucción lingüística posterior y analizar con mayor claridad dónde se originan los errores. Esta propiedad resulta especialmente útil en un contexto experimental, donde la interpretabilidad del sistema es tan importante como el rendimiento agregado.

La variante textual, por su parte, demuestra que la decodificación directa a caracteres es una alternativa viable y conceptualmente más simple. Aunque no alcanzó el mismo rendimiento final que la variante fonética, reduce la dependencia de una representación fonética intermedia y aproxima el modelo directamente a la salida comunicativa deseada. Esta formulación puede resultar especialmente interesante en escenarios futuros, en particular si se trabaja con idiomas de mayor transparencia ortográfica o con modelos de lenguaje mejor adaptados al dominio.

Una aportación relevante del trabajo es la exploración de una arquitectura híbrida ConvMambaGRU aplicada al problema de decodificación neuronal del habla. Hasta donde se ha podido revisar en la literatura, este trabajo constituye una de las primeras aproximaciones que adapta un modelo de tipo ConvMamba a señales neuronales orientadas a "brain-to-text". Aunque esta arquitectura no superó a la línea base GRU, su evaluación resulta valiosa porque muestra tanto el potencial como las dificultades de trasladar modelos de espacio de estados al dominio neural. El resultado sugiere que estas arquitecturas requieren una adaptación más específica al tipo de señal, al volumen de datos disponible y a las restricciones de entrenamiento del problema.

Desde un punto de vista práctico, el trabajo confirma que las arquitecturas recurrentes siguen siendo una referencia sólida para este tipo de tareas. En contextos con datos limitados, señal ruidosa y variabilidad entre sesiones, una arquitectura más compleja no garantiza necesariamente mejores resultados. Esto tiene una implicación importante para desarrollos futuros. Antes de sustituir completamente la arquitectura base, puede ser más efectivo mejorar la estrategia de entrenamiento, la representación objetivo, la adaptación intersesión y la integración con modelos de lenguaje.

El análisis realizado también pone de manifiesto la importancia del modelo de lenguaje como componente del sistema. Tanto en la variante fonética como en la textual, la etapa lingüística posterior actúa como un mecanismo de corrección y priorización de hipótesis. Esta observación refuerza la idea de que los avances en neuroprótesis del habla no dependerán únicamente de mejores decodificadores neuronales, sino también de una integración más estrecha entre señales cerebrales, unidades lingüísticas y modelos de lenguaje capaces de recuperar coherencia contextual.

Finalmente, la incorporación del módulo de síntesis de voz permite mostrar una demostración funcional más cercana a una neuroprótesis de comunicación completa. Aunque en este trabajo la síntesis de voz se plantea como una extensión posterior al texto y no como una reconstrucción directa de la voz desde la actividad neuronal, permite conectar la salida del sistema con una forma de comunicación más natural. Esto refuerza la orientación aplicada del proyecto y abre la puerta a futuras extensiones centradas en voz personalizada, prosodia y sistemas "brain-to-voice".

En conjunto, este trabajo no solo compara varias arquitecturas de decodificación, sino que establece una base experimental reproducible para estudiar cómo interactúan el modelado neuronal, la representación lingüística y la generación de una salida comunicativa final. La principal conclusión es que la restauración de la comunicación mediante señales neuronales requiere optimizar el sistema completo, no únicamente cada componente de forma aislada.

5.2 Limitaciones

A pesar de los resultados obtenidos, este trabajo cuenta con varias limitaciones que deben tenerse en cuenta al interpretar sus conclusiones.

En primer lugar, el estudio se apoya en un único conjunto de datos y en registros procedentes de un único participante. Esto limita la capacidad de generalización de los resultados y hace que las conclusiones deban entenderse dentro de un marco experimental concreto. Aunque este tipo de restricción es habitual en el área, sigue siendo un factor importante al extrapolar el comportamiento del sistema a otros sujetos o contextos clínicos.

En segundo lugar, la comparación entre arquitecturas y configuraciones no ha sido completamente simétrica en todos los casos. En particular, el análisis detallado del efecto

de distintos modelos de lenguaje en la variante textual se realizó únicamente sobre la arquitectura ConvMambaGRU textual, mientras que para la arquitectura GRU textual se utilizó directamente la mejor configuración final obtenida.

En tercer lugar, parte del pipeline de la variante fonética depende de componentes externos heredados del repositorio base, especialmente en lo relativo al uso de Redis y a la integración del modelo de lenguaje original. Aunque esta decisión facilitó la reproducibilidad y la comparabilidad con la línea base, introduce una dependencia adicional y una mayor complejidad operativa.

Otra limitación relevante está relacionada con los recursos computacionales disponibles. El entrenamiento y la evaluación de arquitecturas más complejas, así como el uso de modelos de lenguaje de mayor capacidad, estuvieron condicionados por las restricciones de hardware. Esto limitó el número de configuraciones exploradas y dificultó la reproducción de enfoques más ambiciosos reportados recientemente en la literatura.

Además, el módulo de síntesis de voz implementado no reconstruye directamente la voz del participante a partir de actividad neuronal ni preserva rasgos específicos de su identidad vocal. Se trata de una conversión de texto decodificado a audio mediante un sistema TTS preentrenado, que resulta útil como demostración funcional, pero conceptualmente distinta de los sistemas de síntesis neural directa descritos en los trabajos más avanzados del área. Por último, la evaluación se ha centrado principalmente en métricas de error textual y fonémico sobre el conjunto de validación, sin incorporar una evaluación formal del módulo de síntesis de voz, una medición de comunicación en tiempo real ni una validación de usabilidad en un contexto clínico real. Por todo ello, las conclusiones deben entenderse como resultados experimentales obtenidos en un entorno controlado.

5.3 Líneas de trabajo futuras

A partir de las limitaciones observadas y de los resultados obtenidos, pueden plantearse varias líneas de trabajo futuro que permitirían ampliar y mejorar el sistema desarrollado.

Una primera línea consiste en profundizar en la mejora de la etapa de decodificación lingüística. Los resultados del trabajo muestran que el modelo de lenguaje desempeña un papel decisivo tanto en la variante fonética como en la textual. Por ello, futuras extensiones podrían explorar estrategias de rescoring más avanzadas, modelos de lenguaje de mayor capacidad y métodos de ajuste más específicos al dominio del corpus utilizado.

Una segunda línea de trabajo consiste en explorar representaciones objetivo más ricas que los fonemas aislados. Aunque las unidades dependientes de contexto, como dífonos o trífonos, se utilizan desde hace décadas en reconocimiento automático del habla, su aplicación en sistemas recientes de decodificación neuronal "brain-to-text" vuelve a ser de interés porque permiten capturar mejor las transiciones entre sonidos y el contexto fonético

local [18,19]. En esta misma línea, también podrían estudiarse representaciones subléxicas alternativas, como tokens BPE, que agrupan fragmentos frecuentes de texto y podrían ofrecer un equilibrio distinto entre longitud de secuencia, tamaño del vocabulario e información lingüística disponible para el modelo.

En tercer lugar, sería relevante ampliar la exploración arquitectónica de manera más sistemática y con un presupuesto experimental suficiente. Aunque en este trabajo las variantes híbridas basadas en Mamba no superaron a los modelos GRU, ello no implica que estas arquitecturas carezcan de interés, sino que su integración en este problema requiere probablemente un ajuste más cuidadoso de hiperparámetros, regularización, tamaño del modelo y estrategia de entrenamiento.

Otra línea importante consiste en mejorar la robustez intersesión del sistema. El análisis exploratorio y el análisis de errores sugieren que parte del rendimiento depende de variaciones entre sesiones de registro. En este sentido, sería de gran interés incorporar estrategias de adaptación de dominio, alineamiento entre sesiones o mecanismos explícitos de generalización temporal.

Desde una perspectiva aplicada, una extensión especialmente relevante sería avanzar desde un sistema "brain-to-text" hacia un sistema más cercano a una neuroprótesis de comunicación completa. En este punto, el módulo TTS incorporado en este trabajo constituye solo un primer paso. Futuras líneas podrían incluir la personalización de la voz sintética, la incorporación de prosodia controlada o la evaluación de sistemas más próximos a las aproximaciones recientes de "brain-to-voice".

También sería deseable ampliar la evaluación más allá de las métricas tradicionales. En el caso de la síntesis de voz, por ejemplo, podría realizarse una evaluación de inteligibilidad, naturalidad o calidad percibida. Del mismo modo, en fases posteriores resultaría interesante introducir criterios de usabilidad, velocidad efectiva de comunicación y carga de interacción en escenarios más próximos a un uso real.

Por último, una línea de trabajo importante sería la validación del sistema en más participantes y contextos experimentales. La disponibilidad de nuevos conjuntos de datos, benchmarks compartidos o colaboraciones con otros grupos permitiría estudiar hasta qué punto las conclusiones obtenidas aquí se mantienen en escenarios más amplios.

Estas líneas futuras muestran que el trabajo realizado no cierra el problema, sino que establece una base sólida sobre la que seguir avanzando. La continuidad más natural del proyecto está en mejorar la interacción entre modelado neuronal, representación lingüística y salida comunicativa final, manteniendo al mismo tiempo el énfasis en reproducibilidad, comparabilidad experimental y aplicabilidad real.

6. Bibliografía

- [1] Silva AB, Littlejohn KT, Liu JR, Moses DA, Chang EF. The speech neuroprosthesis. *Nat Rev Neurosci.* 2024;25:473-492.
- [2] Card NS, Wairagkar M, Iacobacci C, et al. An accurate and rapidly calibrating speech neuroprosthesis. *N Engl J Med.* 2024;391:609-618. doi:10.1056/NEJMoa2314132.
- [3] Brumberg JS, Nieto-Castanon A, Kennedy PR, Guenther FH. Brain-computer interfaces for speech communication. *Speech Commun.* 2010;52(4):367-379.
- [4] Wolpaw JR, Birbaumer N, Heetderks WJ, et al. Brain-computer interfaces for communication and control. *Clin Neurophysiol.* 2002;113:767-791.
- [5] Moses DA, Metzger SL, Liu JR, et al. Neuroprosthesis for decoding speech in a paralyzed person with anarthria. *N Engl J Med.* 2021;385:217-227.
- [6] Birbaumer N, Cohen LG. Brain-computer interfaces: communication and restoration of movement in paralysis. *J Physiol.* 2007;579(3):621-636.
- [7] Chang EF. Brain-Computer Interfaces for Restoring Communication. *N Engl J Med.* 2024;391(7):654-657.
- [8] Hickok G, Poeppel D. The cortical organization of speech processing. *Nat Rev Neurosci.* 2007;8(5):393-402.
- [9] Friederici AD. The Brain Basis of Language Processing: From Structure to Function. *Physiol Rev.* 2011;91(4). doi:10.1152/physrev.00006.2011.
- [10] Pulvermüller F. Neural reuse of action perception circuits for language, concepts and communication. *Prog Neurobiol.* 2018;160:1-44.
- [11] Wilson GH, Stavisky SD, Willett FR, et al. Decoding spoken English from intracortical electrode arrays in dorsal precentral gyrus. *J Neural Eng.* 2020;17:066007.
- [12] Alahi MEE, Liu Y, Xu Z, Wang H, Wu T, Mukhopadhyay SC. Recent advancement of electrocorticography (ECoG) electrodes for chronic neural recording/stimulation. *Mater Today Commun.* 2021;29:102853. doi:10.1016/j.mtcomm.2021.102853.
- [13] Metzger SL, Liu JR, Moses DA, et al. Generalizable spelling using a speech neuroprosthesis in an individual with severe limb and vocal paralysis. *Nat Commun.* 2022;13:6510.

- [14] Willett FR, Kunz EM, Fan C, et al. A high-performance speech neuroprosthesis. *Nature*. 2023;620:1031-1036.
- [15] Anumanchipalli GK, Chartier J, Chang EF. Speech synthesis from neural decoding of spoken sentences. *Nature*. 2019;568:493-498. doi:10.1038/s41586-019-1119-1.
- [16] Wairagkar M, Card NS, Singer-Clark T, et al. An instantaneous voice-synthesis neuroprosthesis. *Nature*. 2025;644:145-152. doi:10.1038/s41586-025-09127-3.
- [17] Metzger SL, Littlejohn KT, Silva AB, et al. A high-performance neuroprosthesis for speech decoding and avatar control. *Nature*. 2023;620:1037-1046.
- [18] Li J, Le T, Fan C, Chen M, Shlizerman E. Brain-to-Text Decoding with Context-Aware Neural Representations and Large Language Models. *arXiv*. 2024;arXiv:2411.10657.
- [19] Willett FR, Li J, Le T, Fan C, Chen M, Shlizerman E, et al. Brain-to-Text Benchmark '24: Lessons Learned. *arXiv*. 2024;arXiv:2412.17227.
- [20] Jurafsky D, Martin JH. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models*. 3rd ed. draft. 2025 Aug 24.
- [21] Graves A. Connectionist Temporal Classification. In: *Supervised Sequence Labelling with Recurrent Neural Networks*. Studies in Computational Intelligence, vol 385. Springer, Berlin, Heidelberg; 2012. doi:10.1007/978-3-642-24797-2_7.
- [22] Gu A, Dao T. Mamba: Linear-Time Sequence Modeling with Selective State Spaces. *arXiv*. 2023;arXiv:2312.00752.
- [23] Zevallos R, Cortada-Garcia M, Solito S, Mena C, Peiro-Lilja A, Hernando J. Assessing the Performance and Efficiency of Mamba ASR in Low-Resource Scenarios. *Proc Interspeech 2025*;5198-5202. doi:10.21437/Interspeech.2025-1624.
- [24] Heafield K. KenLM: Faster and Smaller Language Model Queries. In: *Proceedings of the Sixth Workshop on Statistical Machine Translation*. Edinburgh, Scotland: Association for Computational Linguistics; 2011. p. 187-197.
- [25] Eren G, The Coqui TTS Team. Coqui TTS: A deep learning toolkit for Text-to-Speech. *Zenodo*; 2021. Software. doi:10.5281/zenodo.6334862.

7. Anexos

Anexo A. Análisis exploratorio de datos

A.1 Estructura del conjunto de datos

Los datos utilizados en este trabajo se almacenan en archivos en formato HDF5 organizados por sesiones de registro. Esta estructura conserva tanto la señal neuronal como los metadatos asociados a cada ensayo, incluyendo el identificador de sesión, el bloque, el número de ensayo y las secuencias objetivo utilizadas durante el entrenamiento y la evaluación.

Cada ejemplo del conjunto de datos puede interpretarse como un par entrada-salida. La entrada está formada por una secuencia temporal de características neuronales, mientras que la salida corresponde a una representación lingüística de la frase objetivo, ya sea en forma de secuencia fonémica o de caracteres según la variante de decodificación considerada. La Tabla 19 resume los campos principales utilizados en el sistema.

Tabla 19. Descripción de los campos principales del conjunto de datos.

Campo	Tipo / formato	Descripción
input_features	Matriz numérica float32 con forma (T, 512).	Características neuronales de un ensayo
n_time_steps	Entero.	Número de pasos temporales válidos.
seq_class_ids	Vector int32 de longitud fija (500,).	Secuencia objetivo codificada como índices enteros para la variante fonética
seq_len	Entero.	Longitud de la secuencia objetivo antes del relleno
transcription	Vector int32 de longitud fija (500,).	Transcripción textual almacenada como códigos enteros
sentence_label	Cadena de texto.	Frase objetivo en formato textual.
session	Cadena de texto.	Identificador de la sesión de la que procede el ensayo
block_num	Entero	Número de bloque
trial_num	Entero	Índice del ensayo dentro del bloque

La señal de entrada se representa como una secuencia temporal de vectores de dimensión fija, con forma general $[T, 512]$ donde T indica el número de pasos temporales válidos del ensayo. En la configuración de referencia, estas 512 características se interpretan como dos características por cada uno de los 256 electrodos del registro. Esta representación convierte cada ensayo en una secuencia multicanal de longitud variable, lo que condiciona tanto el preprocesado como el diseño de los modelos de decodificación.

La Figura 24 muestra un ejemplo de señal neuronal correspondiente a un ensayo individual. Esta visualización permite observar tanto la evolución temporal global de la señal como la trayectoria de algunas características seleccionadas.

Muestra encontrada en clave HDF5: trial_0039
Shape señal: (741, 512)
Session: t15.2023.11.19 | Block: 2 | Trial: 39
Sentence: What do people think of me?




Figura 24. Ejemplo de señal neuronal de entrada correspondiente a un ensayo individual. Fuente: elaboración propia.

A.2 Distribución de ensayos por sesión

Antes de diseñar el pipeline final, se realizó un análisis exploratorio con el objetivo de caracterizar la estructura del conjunto de datos y detectar propiedades que pudieran condicionar la implementación del sistema. Este análisis se centró en la distribución de ensayos por sesión, la variabilidad de las longitudes temporales de entrada, la longitud de las secuencias objetivo y la relación entre la duración de la señal neuronal y la longitud lingüística.

En primer lugar, se observó que el número de ensayos no está distribuido de forma uniforme entre sesiones. Este aspecto resulta relevante tanto para interpretar la contribución relativa de cada sesión al entrenamiento como para analizar posibles diferencias de rendimiento entre días de registro. La Figura 25 muestra el número de ensayos disponibles por sesión.




Figura 25. Número de ensayos disponibles por sesión de registro. Fuente: elaboración propia.

Esta distribución desigual debe tenerse en cuenta al interpretar los resultados, ya que algunas sesiones tienen mayor peso efectivo en el aprendizaje que otras. Además, puede contribuir a la variabilidad intersesión observada posteriormente en el análisis de errores.

A.3 Longitudes de las secuencias de entrada y salida

En segundo lugar, se analizó la longitud temporal de las secuencias de entrada. Los resultados muestran una variabilidad considerable tanto en entrenamiento como en validación, lo que confirma que los ensayos no pueden tratarse como secuencias de longitud fija. Esta propiedad justifica el uso de mecanismos de relleno por lotes y el mantenimiento explícito de las longitudes reales durante el entrenamiento. Esta distribución puede observarse en la Figura 26.




Figura 26. Distribución de la longitud temporal de las secuencias de entrada en entrenamiento y validación. Fuente: elaboración propia.

De forma análoga, las secuencias objetivo también presentan longitudes variables. Esta variabilidad aparece tanto en la representación fonética como en la textual, aunque cada una responde a una unidad lingüística distinta. La Figura 27 recoge la distribución de longitudes de ambas representaciones.




Figura 27 .Distribución de las longitudes de las secuencias objetivo en las representaciones fonética y textual.
Fuente: elaboración propia.

Estos resultados refuerzan la necesidad de formular el problema como una tarea secuencia-a-secuencia. Dado que ni la señal neuronal ni las salidas lingüísticas presentan una longitud uniforme, el modelo debe aprender a transformar secuencias temporales variables en secuencias simbólicas también variables.

A.4 Relación entre longitud temporal y longitud lingüística

Además de analizar las distribuciones por separado, se estudió la relación entre la longitud temporal de la señal neuronal y la longitud de la secuencia objetivo. Aunque ambas variables muestran una tendencia positiva, la correspondencia no es fija. Es decir, frases de longitud lingüística similar pueden presentar duraciones neuronales distintas, y frases con duraciones similares pueden diferir en el número de fonemas o caracteres. Esta relación se ilustra en la Figura 28.




Figura 28. Relación entre la longitud temporal de entrada y la longitud de la secuencia objetivo. Fuente: elaboración propia.

Esta observación es importante para el diseño del sistema, ya que confirma que no existe un alineamiento directo y trivial entre cada instante de la señal neuronal y cada unidad lingüística de salida. Por ello, el entrenamiento mediante CTC resulta adecuado, al permitir optimizar el modelo sin disponer de alineamientos temporales explícitos entre señal y transcripción.

A.5 Estabilidad y variabilidad intersesión de la señal

Como análisis complementario, se exploró la estabilidad temporal de la señal entre sesiones mediante métricas globales de amplitud y dispersión. En particular, se analizaron medidas como la media del valor absoluto, la desviación estándar y el valor RMS por sesión. La Figura 29 resume este análisis.




Figura 29. Estabilidad temporal global de la señal por sesión de registro, medida mediante la media del valor absoluto, la desviación estándar y el RMS. Fuente: elaboración propia.

Los resultados sugieren una estabilidad general relativamente alta, aunque con variaciones entre sesiones. Estas diferencias pueden estar relacionadas con cambios en la calidad del registro, variaciones en la distribución de ensayos o fluctuaciones propias de los registros neuronales a lo largo del tiempo.

También se analizó la variabilidad media por característica y sesión. La Figura 30 muestra un mapa de calor que permite identificar diferencias en la dispersión de las características neuronales a lo largo de las sesiones de registro.




Figura 30. Mapa de calor de la variabilidad media de la señal por sesión y característica. Fuente: elaboración propia.

Este análisis permite observar que la variabilidad no se distribuye de forma completamente homogénea entre características ni entre sesiones. Aunque el sistema de preprocesado incorpora normalización por sesión para reducir estas diferencias, la variabilidad intersesión sigue siendo un factor relevante para interpretar el rendimiento del modelo y su capacidad de generalización temporal.

A.6 Conclusiones del análisis exploratorio de datos

El análisis exploratorio permite extraer varias conclusiones relevantes para el diseño del sistema. En primer lugar, la dimensionalidad de entrada es constante, ya que todos los ensayos se representan mediante vectores de 512 características por paso temporal. Esta propiedad simplifica la definición de las arquitecturas, al mantener fijo el número de canales de entrada.

En segundo lugar, tanto la señal neuronal como las salidas lingüísticas presentan longitudes variables. Esta característica justifica el uso de una formulación secuencia-a-secuencia, el empleo de zero-padding para agrupar ejemplos en lotes y la conservación de las longitudes reales de cada ensayo durante el entrenamiento y la evaluación.

En tercer lugar, la relación entre duración neuronal y longitud lingüística no es fija. Por ello, el sistema debe aprender un mapeo flexible entre entrada y salida, sin asumir una correspondencia directa entre instantes temporales y unidades fonémicas o textuales. Esta observación respalda el uso de CTC como función de pérdida.

Por último, el análisis de estabilidad y variabilidad intersesión muestra que, aunque la señal presenta una estructura global relativamente consistente, existen diferencias entre sesiones que pueden afectar al rendimiento. Esta conclusión conecta directamente con los resultados del análisis de errores, donde también se observan variaciones de rendimiento entre sesiones de registro.

Anexo B. Repositorio del trabajo desarrollado

El código, notebooks, configuraciones y scripts desarrollados se encuentran disponibles en el siguiente repositorio:

Repositorio principal del TFM:

<https://github.com/LucasZV/TFM-brain-to-text-decoding/>

Este repositorio recoge la implementación experimental de los sistemas propuestos, incluyendo:

- El análisis exploratorio de datos.
- La variante fonética.
- La variante textual.
- Los notebooks de análisis de errores.
- La integración del módulo de síntesis de voz.
- Entornos de ejecución necesarios para la reproducibilidad.

Por restricciones de tamaño de GitHub, no se incluyen en el repositorio todos los checkpoints finales ni algunos logs pesados generados durante el entrenamiento. No obstante, sí se conserva la estructura del proyecto, los scripts, configuraciones, resultados resumidos y ficheros necesarios para reproducir el pipeline experimental.

Anexo C. Repositorio del modelo base utilizado

Como punto de partida para la reproducción de la línea base y para la preparación inicial de datos y evaluación fonética, este trabajo se apoya en el siguiente repositorio externo:

Repositorio base de referencia:

<https://github.com/Neuroprosthetics-Lab/nejm-brain-to-text>

Este repositorio proporciona la implementación de referencia de la línea base reproducible empleado como punto de comparación en este trabajo. En particular, sus instrucciones fueron utilizadas para:

- La descarga y preparación del conjunto de datos.
- La configuración del entorno base.

- La integración del modelo de lenguaje y la evaluación mediante Redis en la rama fonética.

Las arquitecturas, scripts y experimentos desarrollados específicamente en este TFM se han implementado en un repositorio separado, documentado en el Anexo B.

Anexo D. Repositorio Pages.io de reproducción de ejemplos sintetizados

Con el objetivo de facilitar la evaluación cualitativa del módulo de síntesis de voz, se ha creado un repositorio independiente en GitHub Pages que permite reproducir directamente los audios generados mediante Coqui TTS a partir de predicciones de la variante fonética.

- Repositorio de la página web: <https://github.com/LucasZV/TFM-audio-examples>
- Página desplegada: <https://lucaszv.github.io/TFM-audio-examples/>

Este repositorio contiene una página HTML estática con dos ejemplos representativos de síntesis de voz: un caso correctamente decodificado y un caso con error grave en la predicción textual.

Para cada ejemplo se muestra el texto de referencia, el texto predicho utilizado como entrada del sintetizador y un reproductor de audio que permite escuchar directamente el archivo generado.

Los principales elementos incluidos en el repositorio son:

- index.html: página web estática con la descripción de los ejemplos y los reproductores de audio.
- example_001.wav: audio sintetizado correspondiente al ejemplo correctamente decodificado.
- example_010.wav: audio sintetizado correspondiente al ejemplo con error grave de decodificación.
- tts_examples_subplot_2x2.png: figura con la forma de onda y el espectrograma de ambos ejemplos.

Este anexo complementa la Tabla 18 y la Figura 23 de la memoria, proporcionando una forma directa de reproducir los audios generados y comprobar cómo las predicciones textuales del sistema se trasladan a una salida hablada mediante el módulo TTS.

Anexo E. Organización del código y artefactos experimentales

El repositorio principal del TFM se organiza en los siguientes bloques principales:

- EDA/: análisis exploratorio de datos.
- Error_Analysis/: notebooks de análisis de errores de la rama fonética y textual.
- Experiments/Phoneme/: implementación y evaluación de la rama fonética.
- Experiments/Text/: implementación y evaluación de la rama textual.
- Experiments/TTS/: scripts y salidas del módulo de síntesis de voz.
- envs/: entornos Conda y ficheros de dependencias empleados en los distintos experimentos.

Esta organización responde al objetivo de mantener un pipeline modular y reproducible, separando carga de datos, preprocesado, entrenamiento, evaluación, rescoring y síntesis de voz, tal y como se describe en el capítulo de implementación y reproducibilidad.